Как проверить всё самостоятельно

Собрано из файлов проекта командой `.venv/bin/python -m src.human_docs` · коммит 88f2193

Порядок — от самого важного к второстепенному. Все документы лежат в папке `human/`. Команды запускаются в терминале из папки проекта `mk_lab_3`.

Шаг	Что проверяем	Документ	Время
1	Эталоны задач	02	3–4 ч
2	Гипотезы закоммичены до прогонов	03, 04	10 мин
3	Модели, промпт, полнота прогонов	04	20 мин
4	Автопроверка ответов A и F	12	1 ч
5	Тип E (AI4I)	05	30 мин
6	Код D	02, файлы кода	30 мин
7	Слепая проверка B, C, D (вдвоём)	06, 07	3–5 ч на каждого
8	Выборочная проверка парсера	08	30 мин
9	Тарифы	09	20 мин
10	После анализа: числа отчёта и воспроизводимость	11	30 мин

1. Эталоны задач — документ 02 (главное)

На защите могут попросить решить любую задачу, поэтому этот шаг важнее остальных.

1. Для каждой задачи закройте рукой эталон и решите сами на бумаге. Потом сравните с зелёной плашкой «Эталон» и поставьте галочку.
2. **A и F с числами:** под задачей есть код расчёта эталона. Его можно запустить и увидеть то же число: `.venv/bin/python data/refs/A1.py` → строка `REFERENCE: 0.1610`.
3. **F6–F8 («нельзя определить»):** убедитесь, что без недостающего числа ответ действительно не получить и что нельзя честно «додумать» условие.
4. **B:** решите, верно утверждение или нет, и сверьте с эталоном. Проверьте, что ключевые аргументы в рубрике правильные.
5. **C:** согласны ли вы с ожидаемым методом и с тем, за что ставится 2, 1 и 0 баллов.
6. **D:** запустите эталонное решение — должно напечататься то же число, что в эталоне: `.venv/bin/python data/d_reference/D4.py` → `METRIC: 0.9556`.
7. В первую очередь посмотрите задачи, о которых чаще всего спрашивают: A4 и F4 (точка на границе зазора, вопрос самоконтроля 12), F7 и F8 (почему «нельзя определить»), F9 (k-means за 3 итерации, центр «переезжает»), F10 (голосование и среднее дают разные классы).
8. Если нашли ошибку — запишите её. Банк уже прогнан через модели, поэтому правка задачи потребует перепрогона именно этой задачи (ассистент сделает).

2. Гипотезы закоммичены до прогонов — документы 03 и 04

1. В документе 03, таблица «Факт — Значение»: время коммита с прогнозом должно быть **раньше** первого оценочного вызова.

2. То же из терминала: `git log -1 --format=%ci -- hypotheses.md` — время коммита гипотез (14.10.2026 22:00 по Москве); `.venv/bin/python -m src.checks g1` — все строки с ✓, в том числе «нет оценочных вызовов раньше коммита гипотез».
3. Перечитайте свой прогноз и обоснование: на защите спросят, почему вы так думали.

3. Модели, промпт, полнота прогонов — документ 04

1. Таблица «Модели»: 4 модели, у каждой `model_reported` (точная версия) и даты. Температура 0, у GigaChat 0,0001 (API не принимает 0).
2. Таблица «Прогоны по экспериментам»: в столбце «без ответа» везде 0. Техошибки — это сбои сети и API (ночью 15.10 DeepSeek не отвечал), они повторены и ответами модели не считаются.
3. Прочитайте системный промпт и примеры полных запросов: модели получили ровно этот текст.
4. Проверка из терминала, что все 4 модели отвечают: `.venv/bin/python -m src.smoke_test`.

4. Автопроверка ответов A и F — документ 12

1. Для каждой задачи там показаны ответы всех 4 моделей: строка «ОТВЕТ», что распознано, эталон и вердикт автопроверки.
2. Проверьте глазами, что вердикт верный: число совпадает с эталоном в пределах 1% → «верно»; для F6–F8 верно только «нельзя определить».
3. Отдельно посмотрите ответы с пометкой «формат не соблюдён» — там ответ найден эвристикой.
4. Ответы на B, C и D в этот документ намеренно не включены: их вы оцениваете вслепую (шаг 7), и названия моделей видеть нельзя.

5. Тип E — документ 05

1. Убедитесь, что удалены колонки-утечки TWF, HDF, PWF, OSF, RNF (по сути это и есть ответ) и идентификаторы UDI, Product ID.
2. Разбиение: 200 тестовых строк, из них 40 отказов (обогащённый тест — это нужно упомянуть в ограничениях), примеры для промпта в тест не попадают.
3. Пример запроса: так выглядел запрос к модели с 5 примерами.
4. Таблица метрик — только числа; главная метрика — F1 по классу «отказ» и balanced accuracy, accuracy при дисбалансе обманчива (вопрос самоконтроля 5).

6. Код D

1. Код каждой модели лежит в `results/d_code/<модель>/<задача>.py`. Его можно открыть и запустить: `.venv/bin/python results/d_code/qwen3-8b/D4.py`.
2. Методологию (утечки, подбор по тесту и т. д.) вы оцениваете на шаге 7 в листе проверки — там код показан без названия модели. Чтобы не нарушить слепую проверку, открывайте папку `results/d_code` **после** того, как заполните лист.

7. Слепая проверка B, C, D — документы 06 и 07 (вдвоём, независимо)

1. Оба проверяющих читают инструкцию (документ 06).
2. Каждый читает ответы в документе 07 и ставит оценки в свой файл: проверяющий 1 — `grading/sheet_r1.csv`, проверяющий 2 — `grading/sheet_r2.csv` (открывать в Excel или Numbers,

сохранять как CSV UTF-8).
3. Не обсуждать оценки и не открывать `grading/key_DO_NOT_OPEN.csv`.
4. После заполнения: `.venv/bin/python -m src.checks g2`.

8. Выборочная проверка парсера — документ 08

Для каждого из 20 ответов: согласны ли вы с тем, что распознал парсер и с вердиктом. «да / нет» → столбец `human_agrees` в `grading/parser_spotcheck.csv`.

9. Тарифы — документ 09

Откройте ссылки из столбца «источник», сравните цены, впишите дату проверки и поставьте `"verified_by_human": true` в `config/pricing.json`.

10. После анализа — документ 11

1. Запустите `python3 flow/flow.py run`: посчитаются итоговые метрики и графики, пересоберутся отчёт и PDF.
2. Каждое число в отчёте берётся из `results/summary_metrics.json`, который пишет ноутбук `analysis.ipynb`. Откройте ноутбук в Jupyter, выполните Restart & Run All — числа должны совпасть (на защите попросят перезапустить ячейку).
3. Воспроизводимость: `scripts/check_reproducibility.sh` → «совпадает».

Что можно доверить ассистенту, а что — только вам

- Ассистент перепроверил кодом эталоны, автопроверку, метрики типа E, код D и логику H9 (документ 01, раздел «Независимая перепроверка»).
- Только вы: решить задачи и подтвердить эталоны, слепая проверка B/C/D, сверка тарифов, выводы по гипотезам, разбор 5 ошибок, ограничения, рекомендации, ответы на вопросы самоконтроля, доклад.