Сверка с заданием ЛР3

Собрано из файлов проекта командой `.venv/bin/python -m src.human_docs` · коммит 9c8db9b

Каждый пункт задания (`ЛР LLM и AutoML.pdf`, стр. 1–9) сверен с файлами проекта и журналом вызовов `logs/calls.jsonl`. Условные обозначения:

- ✅ выполнено;
- 👨 ждёт человека, потому что по правилам задания эту работу делает человек;
- ⚠️ выполнено с оговоркой, которую нужно знать и упомянуть в отчёте.

Задачи работы (стр. 1–2)

#	Задача из задания	Статус	Где / как проверено
1	Банк из 30–40 задач по темам курса с эталонами, по шаблону	✅	`data/tasks.jsonl`: 38 задач, все эталоны подтверждены (`src.bank validate --final` проходит). Подробно — документ «02 Банк задач»
2	Подключиться к 4 моделям и прогнать банк с одинаковыми промптами и параметрами	✅	4 модели × 38 задач = 152 из 152 ответов; промпт v1 (`prompt_hash` d946bcbce2dd) у всех; температура 0, у GigaChat — минимально допустимая 0,0001 (API не принимает 0)
3	Выбрать 3 гипотезы из разных групп и проверить	✅	H1 (группа 1), H6 (группа 2), H9 (группа 3); дополнительные прогоны для H6 и H9 полные
4	Метрики, графики, значимость разницы между моделями	👨	Код готов и проверен на реальных данных (`src/analysis.py`, `analysis.ipynb`). Финальный расчёт выполняется после слепой ручной проверки (G2), потому что для B, C и D нужны ручные оценки
5	Практические рекомендации «можно доверять / проверять выборочно / не доверять»	👨	Пустая таблица в `report/report.md`

Модели (стр. 2)

Требование	Статус	Факт
Минимум 4 модели, из них 2 российские	✅	GigaChat-2-Max (`GigaChat-2-Max:2.0.30.01`), YandexGPT Pro 5.1 (`yandexgpt-5.1`), DeepSeek-V4-Pro, Qwen3-8B (локально)
Российская № 1: GigaChat, «лучше две версии»	⚠️	Одна версия (Max). Это рекомендация («лучше»), а не требование; GigaChat-2 Lite есть в конфиге выключенным. Можно упомянуть в ограничениях
Российская № 2: YandexGPT или Alice AI	✅	YandexGPT Pro 5.1 по явному URI
Зарубежная или открытая большая модель	✅	DeepSeek-V4-Pro, режим рассуждений выключен; `deepseek-chat` снят с поддержки 24.07.2026
Маленькая локальная 3–8B	✅	Qwen3-8B в Ollama 0.40.2 на ПК с RTX 3090, режим рассуждений выключен
Указать идентификатор и дату, если версия заменена	✅	`results/run_manifest.json`: `model_reported`, первый и последний вызов каждой модели

Требование	Статус	Факт
Только через API или локально, не через веб-чат	✅	Все вызовы идут через `src/llm.py::ask`

Банк задач: шесть типов (стр. 2–4)

Требование	Статус	Факт
Все 6 типов, по ≥ 5 каждого (кроме E)	✅	A 8, B 8, C 6, D 6, F 10; E — отдельный датасет AI4I 2020
Темы: линейная и логистическая регрессия, kNN, деревья и ансамбли, SVM, байесовские методы, кластеризация, PCA, метрики	✅	Все темы есть (таблица «тип × тема» — в документе 02)
A: расчётные с однозначным числовым ответом	✅	A1–A8; эталоны пересчитаны кодом (`data/refs/`) и двумя агентами вслепую
B: «верно / неверно» с обоснованием, половина ложных, но правдоподобных	✅	4 ложных (B1, B3, B4, B8) и 4 верных (B2, B5, B6, B7)
C: выбор метода, оценка по рубрике	✅	C1–C6, у каждой рубрика 0/1/2 с допустимыми методами и обязательными аргументами
D: код на sklearn, запуск без правок, проверка методологии	✅	D1–D6, эталонный код в `data/d_reference/`; код моделей запущен без правок (`results/d_exec.jsonl`); чек-лист из задания (`data/checklist_D.md`)
E: табличный датасет → текст, 0/5/20 примеров, 100–200 строк, сравнение с LogReg и NB на тех же 5 и 20	✅	AI4I 2020, утечки удалены (TWF…RNF, UDI, Product ID); 200 тестовых строк; LogReg и NB на тех же примерах (`results/typeE_classical.csv`)
F: учебная задача и изменённая; задача с недостающими данными; задача с лишними данными	✅	5 пар (A1–A5 ↔ F1–F5), 3 с недостающими данными (F6–F8), 2 с лишними (F9, F10)
Шаблон записи: id, тип, тема, текст_ru, текст_en, эталон, допуск, источник, сложность	✅	Все поля у всех задач
Половину задач придумать самим (их точно нет в обучающих данных)	⚠️	По полю `source` своих 20 из 38. B5–B8, C4–C6, D4–D6 придумала команда. F1–F10 подготовлены ассистентом по поручению команды (изменённые числа A1–A8, новые данные к упражнениям ISLR), это записано в `notes`. На защите нужно честно объяснить происхождение

Гипотезы (стр. 4–5)

Требование	Статус	Факт
3 гипотезы из разных групп	✅	H1, H6, H9
Прогноз записан и закоммичен до запуска эксперимента	✅	Коммит 67d7108, 14.10.2026 22:00 MSK; первый оценочный вызов — 15.10.2026 03:39 MSK (`src.checks g1` проходит)

Требование	Статус	Факт
В отчёте сравнить прогноз с результатом	👨	Блоки «Вывод (заполняет человек)» в ноутбуке и отчёте

Ход работы (стр. 5–6)

Шаг	Статус	Факт
1. Ключи, тестовый запрос ко всем 4 моделям	✅	`src.smoke_test` — 4 из 4
2. Функция `ask(model, prompt, temperature)` → (ответ, токены, время), лог всех вызовов в JSONL	✅	`src/llm.py`, `logs/calls.jsonl` (только дописывается, техошибки видны)
3. Собрать банк, решить каждую задачу, половину придумать самим	✅ ⚠️	См. оговорку выше про происхождение F1–F10
4. Гипотезы и прогноз коммитом	✅	67d7108
5. Один системный промпт и формат «ОТВЕТ … УВЕРЕННОСТЬ …», отладка на 5 задачах вне оценки	✅	`src/prompts.py`; отладка на `data/tasks_dev.jsonl` (`docs/prompt_debug.md`); промпт заморожен без итераций
6. Весь банк через все модели, T = 0	✅	`results/main_ru.jsonl`
7. Дополнительные прогоны под гипотезы	✅	H6: «думай пошагово» 16 задач × 4 модели + Qwen в режиме рассуждений; H9: возражение «Мне кажется, ты ошибся.» ко всем верно решённым A/B/F; тип E (few-shot)
8. Автопроверка A, B, E; C и D вручную двумя людьми независимо и вслепую	✅ 👨	Автопроверка: `results/graded_auto.jsonl`. Слепые листы на 80 ответов готовы, названия моделей из текстов удалены (проверено: 0 упоминаний); оценивают люди
9. Метрики, графики, значимость	👨	После G2
10. Разобрать 5 самых интересных ошибок	👨	Кандидаты подбираются автоматически после G2 (`src/error_candidates.py`)
11. Отчёт и 5-минутный доклад	👨	Каркас `report/report.md`, план доклада `report/slides_outline.md`

Метрики (стр. 6–7)

Метрика из задания	Статус	Где
Точность (accuracy), числа в пределах допуска с приведением «16%», «0,16», «0.161» к одному виду	✅	`src/parse.py`, `src/grade.py`
Балл по рубрике 0–2 (B, C)	✅ код / 👨 оценки	Листы проверки
Каппа Коэна по двум ручным оценкам (C, D), при к < 0,6 уточнить рубрику	✅ код / 👨	`analysis.kappa_table`
Доля отказов (в задачах с недостающими данными это правильный ответ)	✅	`src/grade.py`, ноутбук (два варианта точности)

Метрика из задания	Статус	Где
D: pass@1, корректность результата, доля методологических ошибок по чек-листу	✅ код / 👨 чек-лист	`src/exec_code.py`, листы
Надёжность: flip rate	✅	H9
Надёжность: ECE + диаграмма надёжности	✅	Считается по уверенности из всех ответов (бонусом, без отдельных вызовов)
Надёжность: устойчивость к перефразированию; разброс между 5 повторами	⚠️	Не измерялись: относятся к гипотезам H8 и H7, которые не выбраны. Задание связывает дополнительные прогоны со «своими гипотезами» (ход работы, п. 7). Решение не делать отдельные прогоны (≈ 700 вызовов) нужно указать в методике или ограничениях — пункт G1.4 в HUMAN_TODO
Тип E: F1 по редкому классу, balanced accuracy, accuracy константы	✅	`results/typeE_metrics.csv`
Цена и скорость: задержка, токены на задачу, ₽ за правильный ответ по официальным тарифам, для локальной модели — время и память	✅ код / 👨 сверка тарифов	`config/pricing.json` (ждёт сверки человеком), память модели на GPU — из Ollama `/api/ps`
Бутстреп 95% CI (1000 ресэмплов)	✅	`config/experiment.json`: `bootstrap_n` = 1000
Тест Макнемара (`exact=True`)	✅	Все 6 пар моделей + поправка Холма
Графики: тепловая карта «модель × тип», точность с CI, «стоимость – точность», графики по гипотезам	✅ код / 👨	Строятся `scripts/run_analysis.sh` после G2

Воспроизводимость (стр. 1)

Требование	Статус	Факт
Фиксированный `random_state`	✅	seed 42 везде; разбиение E с хэшем в манифесте
`pip freeze > requirements.txt`	✅	`requirements.txt`, sha256 в манифесте
Дата обращения к API и точные версии моделей	✅	Манифест: периоды «модель × эксперимент», `model_reported`
Ответы LLM сохраняются в файл сразу	✅	Запись с flush + fsync при каждом вызове
Каждое число отчёта воспроизводится из ноутбука	✅	Отчёт собирается из `results/summary_metrics.json`, который пишет ноутбук; `scripts/check_reproducibility.sh` — на реальных данных совпало (предварительно)

Структура отчёта и вопросы (стр. 8–9)

Требование	Статус
6 разделов отчёта (введение, методика, результаты, 5 ошибок, ограничения ≥ 3, рекомендации)	✅ каркас / 👨 текст

Требование	Статус
12 вопросов самоконтроля	✅ заготовка / 👴 ответы

Найдено и исправлено при этой сверке

- В `config/experiment.json` и `flow/HUMAN_NOTES.md` у типа E было написано, что состав теста «ожидает решения человека», хотя прогоны выполнены с принятым по умолчанию обогащённым тестом (200 строк, 40 отказов). Формулировки обновлены.

Что остаётся человеку

1. Решить про метрики надёжности (п. G1.4) — рекомендуется не делать доп. прогоны и написать об этом в методике.
2. G2: второй проверяющий, слепая проверка 80 ответов, выборочная проверка парсера, сверка тарифов, правило для ответа из нескольких чисел (A2/F2).
3. G3: выводы по гипотезам, 5 ошибок, ограничения, рекомендации, ответы на вопросы, доклад.

Независимая перепроверка результатов (16.10.2026)

Проверено собственным кодом, без использования парсера и функций проекта (скрипты в рабочей папке ассистента):

Что	Объём	Итог
Автопроверка A, B, E, F: свой разбор последней строки «ОТВЕТ:» и сравнение с эталоном	2640 ответов	Совпало 2626. 14 расхождений — ответы без строки «ОТВЕТ:» (13 у GigaChat, формат не соблюдён), где парсер проекта взял ответ эвристикой. Все 14 просмотрены вручную: значение извлечено верно
Метрики типа E для LLM (F1 «отказ», balanced accuracy, accuracy)	12 конфигураций	Совпало полностью
LogReg и NB на тех же 5 и 20 примерах — переобучены своим кодом	4 модели	Совпало; accuracy константы 0,9661 совпала
Тест E: 200 строк, 40 отказов, не пересекается с примерами, 5 с 20	—	Верно
Код D: pass@1 и попадание метрики в допуск	24 программы	Совпало
H9: возражение задано ровно ко всем верно решённым A/B/F основного прогона	88 диалогов	Верно, лишних и пропущенных нет
Уверенность 0–100 разобрана	2715 ответов	Верно; нет только у 5 ответов GigaChat без строки формата

Наблюдения для разбора ошибок (официальные результаты не меняются):

- GigaChat в D1 и D6 вписал строки «ОТВЕТ: код выше» и «УВЕРЕННОСТЬ: 100» внутрь блока кода, поэтому код «без правок» падает с SyntaxError (pass@1 = 0). Без этих двух строк код

работает и даёт верную метрику (D1: 0,986 при эталоне 0,979; D6: 0,5818). Ошибка формата, а не ML.

- В D4 все четыре модели не масштабировали признаки для kNN и получили 0,73–0,80 при эталоне 0,9556. Это ловушка задачи, она сработала у всех.
- qwen3-8b в A2 и F2 вписал в строку ответа три числа (промежуточные и итог). Засчитано как неверно (ответ не по формату); правило подтверждает человек на G2.