# Банк задач ЛР3

Собрано из файлов проекта командой `.venv/bin/python -m src.human_docs` · коммит ac61927

В банке 38 задач: своих (поле `source`) — 20, учебниковых — 18. В типе B ложных утверждений 4, верных 4. Тип E — отдельный датасет AI4I 2020 (документ 05). Пары для H1: A1–A5 ↔ F1–F5 (общий `pair_id`).

> Как проверять: решите задачу сами, сверьте с эталоном, поставьте галочку. Замечания пишите на полях; исправления вносятся в `data/tasks.jsonl`. Важно: банк уже прогнан через модели, поэтому любая правка условия означает перепрогон этой задачи.

## Состав банка: тип × тема

| тип | линейная регрессия | логистическая регрессия | kNN | деревья | ансамбли | SVM | байесовские методы | кластеризация | PCA | метрики качества | всего |
|---|---|---|---|---|---|---|---|---|---|---|---|
| A — расчётная | 1 | 1 | 1 | 1 | | 1 | 1 | | 1 | 1 | 8 |
| B — верно / неверно | 1 | 1 | 1 | | 1 | | 1 | 1 | 1 | 1 | 8 |
| C — выбор метода | | 1 | | | 1 | 1 | 1 | 1 | 1 | | 6 |
| D — код sklearn | 1 | | 1 | | 1 | 1 | | 1 | 1 | | 6 |
| F — ловушка | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 10 |
| всего | 4 | 4 | 4 | 2 | 4 | 4 | 4 | 4 | 5 | 3 | 38 |

## Тип A — расчётная

### A1

расчётная · байесовские методы · учебниковый оригинал (пара P1) · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Датчик неисправности срабатывает в 95% случаев при наличии дефекта и в 5% случаев без него. Дефект есть у 1% деталей. Датчик сработал. Какова вероятность того, что деталь дефектная?

**EN:** A fault sensor fires in 95% of cases when a defect is present and in 5% of cases when there is no defect. 1% of parts are defective. The sensor has fired. What is the probability that the part is defective?

> **Эталон: 0,161**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/A1.py)**

```
# A1: формула Байеса. P(D)=0.01, P(+|D)=0.95, P(+|не D)=0.05. Найти P(D|+).
p_d, p_pos_d, p_pos_nd = 0.01, 0.95, 0.05
p_pos = p_pos_d * p_d + p_pos_nd * (1 - p_d)   # полная вероятность срабатывания
print(f"REFERENCE: {p_pos_d * p_d / p_pos:.4f}")
```

> **Заметки:** Пример из PDF задания (тип A). Эталон: data/refs/A1.py, P(D|+) = 0,0095/0,059 ≈ 0,161 (16,1%). Пара P1 с F1 (H1). formula_ru/en и verbal_ru/en — формульная и словесная версии для H2 (черновик агента; числа те же, что в условии); paraphrase_* — черновик агента для H8.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

### A2

расчётная · деревья · учебниковый оригинал (пара P2) · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** В узле дерева решений 40 объектов класса 0 и 10 объектов класса 1. Разбиение даёт левый узел (35 объектов класса 0; 2 объекта класса 1) и правый узел (5; 8). Найдите прирост информации по критерию Джини (неопределённость Джини родителя минус взвешенная неопределённость потомков).

**EN:** A decision tree node contains 40 objects of class 0 and 10 objects of class 1. A split produces a left node (35 objects of class 0; 2 objects of class 1) and a right node (5; 8). Find the information gain using the Gini criterion (Gini impurity of the parent minus the weighted Gini impurity of the children).

> **Эталон: 0,1212**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/A2.py)**

```
# A2: прирост информации по Джини. Родитель (40; 10), левый (35; 2), правый (5; 8).
def gini(counts):
    n = sum(counts)
    return 1 - sum((c / n) ** 2 for c in counts)

parent, left, right = (40, 10), (35, 2), (5, 8)
n = sum(parent)
weighted = sum(left) / n * gini(left) + sum(right) / n * gini(right)
print(f"REFERENCE: {gini(parent) - weighted:.4f}")
```

> **Заметки:** Пример из PDF задания (тип A). Эталон: data/refs/A2.py: 0,32 − (37/50·0,1023 + 13/50·0,4734) ≈ 0,1212. Пара P2 с F2 (H1).

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

### A3

расчётная · метрики качества · учебниковый оригинал (пара P3) · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** Матрица ошибок бинарного классификатора: TP = 30, FP = 10, FN = 20, TN = 940. Найдите accuracy, precision, recall и F1 (в этом порядке).

**EN:** Confusion matrix of a binary classifier: TP = 30, FP = 10, FN = 20, TN = 940. Find accuracy, precision, recall and F1 (in this order).

> **Эталон: 0,97; 0,75; 0,6; 0,6667**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/A3.py)**

```
# A3: метрики по матрице ошибок TP=30, FP=10, FN=20, TN=940.
tp, fp, fn, tn = 30, 10, 20, 940
accuracy = (tp + tn) / (tp + fp + fn + tn)
precision = tp / (tp + fp)
recall = tp / (tp + fn)
f1 = 2 * precision * recall / (precision + recall)
print(f"REFERENCE: {accuracy:.4f}; {precision:.4f}; {recall:.4f}; {f1:.4f}")
```

**Заметки:** Пример из PDF задания (тип А). Эталон: data/refs/A3.py. Пара P3 с F3 (H1).

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## A4

расчётная · SVM · учебниковый оригинал (пара P4) · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Для разделяющей гиперплоскости линейного SVM w = (3; 4), b = –2 (класс определяется знаком w·x + b). Найдите ширину зазора (расстояние между гиперплоскостями w·x + b = 1 и w·x + b = –1) и класс точки (1; 0) (+1 или –1). Ответ: два числа — ширина и класс.

**EN:** For the separating hyperplane of a linear SVM w = (3; 4), b = –2 (the class is the sign of w·x + b). Find the margin width (the distance between the hyperplanes w·x + b = 1 and w·x + b = –1) and the class of the point (1; 0) (+1 or –1). Answer: two numbers — the width and the class.

**Эталон: 0,4; 1**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/A4.py)**

```
# A4: SVM, w=(3; 4), b=−2. Ширина зазора 2/||w|| и класс точки (1; 0).
import numpy as np

w, b, x = np.array([3.0, 4.0]), -2.0, np.array([1.0, 0.0])
width = 2 / np.linalg.norm(w)
score = w @ x + b                    # = 1: точка лежит ровно на границе зазора
label = 1 if score > 0 else -1
print(f"REFERENCE: {width:.4f}; {label}")
```

**Заметки:** Пример из PDF задания (тип А). Эталон: data/refs/A4.py: 2/‖w‖ = 0,4; w·x + b = 1 > 0 → +1. В PDF «ширина зазора» без уточнения; уточнение добавлено, чтобы не путать 2/‖w‖ и 1/‖w‖. Вопрос самоконтроля № 12 — что модель могла бы заметить: точка (1; 0) лежит ровно на границе зазора (w·x + b = 1, расстояние до разделяющей гиперплоскости 1/‖w‖ = 0,2); если SVM обучен на выборке с этой точкой, она опорный вектор. Класс при этом однозначен (+1). Это видно только из текста ответа (автопроверка смотрит числа). Пара P4 с F4 (H1).

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## A5

расчётная · линейная регрессия · учебниковый оригинал (пара P5) · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** По пяти наблюдениям (x; y): (1; 2), (2; 4), (3; 5), (4; 4), (5; 5) методом наименьших квадратов постройте модель y = b0 + b1·x. Найдите b0, b1 и прогноз при x = 6 (в этом порядке).

**EN:** Using five observations (x; y): (1; 2), (2; 4), (3; 5), (4; 4), (5; 5), fit the model y = b0 + b1·x by ordinary least squares. Find b0, b1 and the prediction at x = 6 (in this order).

**Эталон: 2,2; 0,6; 5,8**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/A5.py)**

```
# A5: МНК для y = b0 + b1*x по 5 точкам и прогноз в x = 6.
import numpy as np

x = np.array([1, 2, 3, 4, 5], dtype=float)
y = np.array([2, 4, 5, 4, 5], dtype=float)
b1 = ((x - x.mean()) * (y - y.mean())).sum() / ((x - x.mean()) ** 2).sum()
b0 = y.mean() - b1 * x.mean()
print(f"REFERENCE: {b0:.4f}; {b1:.4f}; {b0 + b1 * 6:.4f}")
```

**Заметки:** Классический учебный пример МНК. Эталон: data/refs/A5.py: b1 = Sxy/Sxx = 6/10, b0 = 4 – 0,6·3. Пара P5 с F5 (H1).

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## A6

расчётная · логистическая регрессия · учебниковый оригинал (пара P6) · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Логистическая регрессия оценивает вероятность сдать экзамен по числу часов подготовки h: P(сдал) = σ(b0 + b1·h), где σ(z) = 1/(1 + e^(–z)), b0 = –4,1, b1 = 1,5. Найдите вероятность сдать экзамен при h = 3 и число часов, при котором эта вероятность равна 0,5 (в этом порядке).

**EN:** A logistic regression estimates the probability of passing an exam from the number of study hours h: P(pass) = σ(b0 + b1·h), where σ(z) = 1/(1 + e^(–z)), b0 = –4.1, b1 = 1.5. Find the probability of passing at h = 3 and the number of hours at which this probability equals 0.5 (in this order).

**Эталон: 0,5987; 2,7333**, допуск ±1% (относительный)

### Расчёт эталона кодом (data/refs/A6.py)

```
# A6: логистическая регрессия p = sigmoid(b0 + b1*h), b0=-4.1, b1=1.5.
import math

b0, b1 = -4.1, 1.5
p3 = 1 / (1 + math.exp(-(b0 + b1 * 3)))   # вероятность при h = 3
h50 = -b0 / b1                             # p = 0.5 там, где b0 + b1*h = 0
print(f"REFERENCE: {p3:.4f}; {h50:.4f}")
```

**Заметки:** Классический пример «часы подготовки → сдал экзамен» (коэффициенты округлены). Эталон: data/refs/A6.py: σ(0,4) ≈ 0,5987; h = 4,1/1,5 ≈ 2,733. Пара P6 с F6 (missing_data, H3).

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## A7

расчётная · kNN · учебниковый оригинал (пара P7) · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** Обучающая выборка для kNN-регрессии (признаки (x1; x2) → целевая переменная y): (1; 1) → 2, (2; 1) → 3, (4; 3) → 6, (5; 4) → 7, (1; 3) → 4, (3; 5) → 8. Предскажите y для точки (2; 2) методом k ближайших соседей с k = 3 и евклидовым расстоянием (прогноз — среднее y соседей без весов).

**EN:** Training set for kNN regression (features (x1; x2) → target y): (1; 1) → 2, (2; 1) → 3, (4; 3) → 6, (5; 4) → 7, (1; 3) → 4, (3; 5) → 8. Predict y for the point (2; 2) with k nearest neighbours, k = 3, Euclidean distance (the prediction is the unweighted mean y of the neighbours).

**Эталон: 3**, допуск ±1% (относительный)

### Расчёт эталона кодом (data/refs/A7.py)

```
# A7: kNN-регрессия, k=3, евклидово расстояние, прогноз = среднее y трёх соседей.
import numpy as np

X = np.array([[1, 1], [2, 1], [4, 3], [5, 4], [1, 3], [3, 5]], dtype=float)
y = np.array([2.0, 3.0, 6.0, 7.0, 4.0, 8.0])
query = np.array([2.0, 2.0])
dist = np.linalg.norm(X - query, axis=1)
order = np.argsort(dist)
print("расстояния по возрастанию:", np.round(dist[order], 3))   # проверка, что нет ничьей на 3-м месте
print(f"REFERENCE: {y[order[:3]].mean():.4f}")
```

**Заметки:** Типовая учебная задача на kNN. Эталон: data/refs/A7.py: соседи (2;1), (1;1), (1;3) на расстояниях 1; 1,414; 1,414; четвёртый на 2,236 — ничьей нет. Пара P7 с F7 (missing_data, H3).

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## A8

расчётная · PCA · учебниковый оригинал (пара P8) · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Ковариационная матрица двух центрированных признаков равна [[2, 1], [1, 2]]. Найдите дисперсии вдоль первой и второй главных компонент и долю дисперсии, объясняемую первой главной компонентой (в этом порядке).

**EN:** The covariance matrix of two centred features is [[2, 1], [1, 2]]. Find the variances along the first and the second principal components and the proportion of variance explained by the first principal component (in this order).

> **Эталон: 3; 1; 0,75**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/A8.py)**

```
# A8: PCA по ковариационной матрице [[2, 1], [1, 2]]: собственные значения и доля дисперсии PC1.
import numpy as np

cov = np.array([[2.0, 1.0], [1.0, 2.0]])
eig = np.sort(np.linalg.eigvalsh(cov))[::-1]
print(f"REFERENCE: {eig[0]:.4f}; {eig[1]:.4f}; {eig[0] / eig.sum():.4f}")
```

> **Заметки:** Типовая учебная задача на PCA. Эталон: data/refs/A8.py: собственные значения 3 и 1, доля 0,75. Пара P8 с F8 (missing_data, H3).

---

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## Тип B — верно / неверно

### B1

верно / неверно · kNN · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** Верно или неверно утверждение: «Увеличение числа соседей k в kNN всегда уменьшает ошибку на тестовой выборке, потому что модель меньше переобучается»? Обоснуйте ответ.

**EN:** Is the following statement true or false: "Increasing the number of neighbours k in kNN always reduces the test error because the model overfits less"? Justify your answer.

> **Эталон: неверно**

**Рубрика**

**Ключевые аргументы:**

- рост k уменьшает дисперсию (граница сглаживается), но увеличивает смещение
- при слишком большом k модель недообучается и тестовая ошибка растёт; при k = n — всегда самый частый класс
- зависимость тестовой ошибки от k обычно U-образная, а не монотонная

**Типичные ошибки:**

- ответ «верно» со ссылкой на уменьшение переобучения
- путать ошибку на обучающей и на тестовой выборке

| Балл | Критерий |
|---|---|
| 2 | «неверно» и объяснено, что большой k ведёт к недообучению (рост смещения) |
| 1 | «неверно», но обоснование неполное (нет недообучения/смещения) или с ошибкой |
| 0 | вердикт неверный или обоснования нет |

> **Заметки:** Пример из PDF задания (тип B), формулировка уточнена: в PDF «всегда уменьшает переобучение» — спорно (переобучение действительно падает), поэтому утверждение сделано про тестовую ошибку. Ложное.

☐ Решил(а) сам(а), эталон верен ☐ Есть замечание: _____

## B2

верно / неверно · ансамбли · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** Верно или неверно утверждение: «Случайный лес не требует масштабирования признаков, а SVM с RBF-ядром требует»? Обоснуйте ответ.

**EN:** Is the following statement true or false: "A random forest does not require feature scaling, while an SVM with an RBF kernel does"? Justify your answer.

> **Эталон: верно**

**Рубрика**

**Ключевые аргументы:**

- деревья разбивают по порогу одного признака: монотонное преобразование признака не меняет разбиения
- RBF-ядро зависит от евклидова расстояния: признак с большим масштабом доминирует, gamma теряет смысл

**Типичные ошибки:**

- ответ «неверно», потому что «масштабирование нужно всегда»
- утверждать, что случайному лесу масштабирование заметно помогает

| Балл | Критерий |
|---|---|
| 2 | «верно» и названы обе причины (пороги в деревьях, расстояния в RBF) |
| 1 | «верно», но объяснена только одна часть или есть ошибка в объяснении |
| 0 | вердикт неверный или обоснования нет |

> **Заметки:** Пример из PDF задания (тип B). Истинное.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## B3

верно / неверно · байесовские методы · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Верно или неверно утверждение: «Наивный байесовский классификатор даёт хорошо откалиброванные вероятности, потому что он вероятностный»? Обоснуйте ответ.
**EN:** Is the following statement true or false: "The naive Bayes classifier produces well-calibrated probabilities because it is a probabilistic model"? Justify your answer.

> **Эталон: неверно**

### Рубрика

**Ключевые аргументы:**

- предположение об условной независимости признаков обычно нарушено: зависимые признаки учитываются многократно, вероятности смещаются к 0 и 1 (переуверенность)
- вероятностная модель не означает калиброванных вероятностей; калибровку проверяют диаграммой надёжности
- исправляется калибровкой (Platt, isotonic, CalibratedClassifierCV)

**Типичные ошибки:**

- ответ «верно», раз модель «выдаёт вероятности»
- путать хорошую точность классификации с хорошей калибровкой

| Балл | Критерий |
|---|---|
| 2 | «неверно» и названа причина (нарушение независимости → переуверенные вероятности) |
| 1 | «неверно», но причина не названа или объяснена с ошибкой |
| 0 | вердикт неверный или обоснования нет |

> **Заметки:** Пример из PDF задания (тип B). Ложное.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## B4

верно / неверно · PCA · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** Верно или неверно утверждение: «PCA выбирает направления, лучше всего разделяющие классы»? Обоснуйте ответ.
**EN:** Is the following statement true or false: "PCA selects the directions that best separate the classes"? Justify your answer.

> **Эталон: неверно**

### Рубрика

**Ключевые аргументы:**

- PCA — метод без учителя: метки классов не используются
- PCA ищет направления максимальной дисперсии; они могут не разделять классы
- направления, разделяющие классы, ищет LDA (линейный дискриминант Фишера)

**Типичные ошибки:**

- ответ «верно», путая PCA и LDA
- считать, что большая дисперсия всегда означает лучшее разделение

| Балл | Критерий |
|---|---|
| 2 | «неверно» + хотя бы один из доводов: PCA не использует метки или максимизирует дисперсию, а не разделимость |
| 1 | «неверно», но обоснование с ошибкой или без этих доводов |
| 0 | вердикт неверный или обоснования нет |

> **Заметки:** Пример из PDF задания (тип B). Ложное.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## B5

верно / неверно · кластеризация · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Верно или неверно утверждение: «Алгоритм кластеризации с более высоким средним коэффициентом силуэта может хуже восстанавливать истинную структуру групп в данных, чем алгоритм с более низким коэффициентом силуэта»? Обоснуйте ответ.

**EN:** Is the following statement true or false: "A clustering algorithm with a higher mean silhouette coefficient can recover the true group structure of the data worse than an algorithm with a lower silhouette coefficient"? Justify your answer.

> **Эталон: верно**

### Рубрика

**Ключевые аргументы:**

- коэффициент силуэта — внутренняя метрика: оценивает компактность кластеров и их отделённость друг от друга, истинные метки не использует
- высокий силуэт не гарантирует соответствия кластеров истинным группам объектов
- метрика предпочитает компактные (выпуклые) кластеры, даже если реальные группы имеют сложную геометрическую форму
- пример: k-means может разрезать кольцеобразный кластер на части и получить силуэт выше, чем HDBSCAN, который корректно выделит исходную структуру

**Типичные ошибки:**

- утверждение, что максимальный коэффициент силуэта всегда соответствует наилучшей кластеризации
- путаница между внутренними и внешними метриками качества кластеризации
- предположение, что коэффициент силуэта непосредственно измеряет соответствие истинным меткам
- игнорирование влияния формы кластеров на оценку качества

| Балл | Критерий |
|---|---|
| 2 | правильно определена истинность утверждения («верно»), объяснено ограничение коэффициента силуэта и приведён пример |
| 1 | правильно определена истинность, но обоснование неполное |
| 0 | неверный ответ или некорректное обоснование |

> **Заметки:** Свой вопрос (14.10.2026) по лекции «Отбор признаков и кластеризация», слайд 28: k-means и GMM — силуэт ≈ 0,5 при ARI ≈ 0,5, HDBSCAN — силуэт 0,34 при ARI 0,97. Верное.

---

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## B6

верно / неверно · линейная регрессия · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Верно или неверно утверждение: «Если добавить новый признак в линейную регрессию без регуляризации и заново обучить модель методом МНК, ошибка на обучающих данных не увеличится, даже если новый признак бесполезный»? Обоснуйте ответ.

**EN:** Is the following statement true or false: "If we add a new feature to linear regression without regularization and retrain it using least squares, the training error will not increase, even if the new feature is useless"? Justify your answer.

> **Эталон: верно**

### Рубрика

**Ключевые аргументы:**

- МНК подбирает коэффициенты так, чтобы минимизировать сумму квадратов ошибок
- если новый признак не помогает, модель может просто поставить его коэффициент равным нулю
- поэтому минимальная ошибка MSE на обучающих данных не может увеличиться, но на тестовых данных качество может ухудшиться

**Типичные ошибки:**

- утверждение, что бесполезный признак обязательно увеличит ошибку на обучении
- путаница между ошибкой на обучающих и тестовых данных
- утверждение, что добавление признака всегда улучшает качество модели

| Балл | Критерий |
|---|---|
| 2 | «верно» и объяснено, что старое решение с нулевым коэффициентом при новом признаке остаётся допустимым, поэтому минимум ошибки на обучении не растёт |
| 1 | «верно», но обоснование неполное (нет аргумента про нулевой коэффициент / вложенность моделей) или с ошибкой |
| 0 | вердикт неверный или обоснования нет |

> **Заметки:** Свой вопрос (14.10.2026). Верное: модели вложены, минимум SSE по более широкому множеству коэффициентов не больше. Критерии score_0/1/2 дописаны ассистентом по образцу B1–B4.

---

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## B7

верно / неверно · логистическая регрессия · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Верно или неверно утверждение: «Если в логистической регрессии увеличить порог с 0.5 до 0.7, вероятности, которые выдаёт модель, не изменятся, но объектов, отнесённых к положительному классу, может стать меньше»? Обоснуйте ответ.

**EN:** Is the following statement true or false: "If we increase the classification threshold in logistic regression from 0.5 to 0.7, the predicted probabilities will stay the same, but fewer objects may be classified as positive"? Justify your answer.

> **Эталон: верно**

### Рубрика

**Ключевые аргументы:**

- логистическая регрессия сначала вычисляет вероятность принадлежности объекта к положительному классу
- порог используется только для перевода вероятности в метку класса, поэтому его изменение не влияет на сами вероятности
- при увеличении порога часть объектов, которые раньше относились к положительному классу, может перейти в отрицательный

**Типичные ошибки:**

- утверждение, что изменение порога меняет вероятности, рассчитанные моделью
- путаница между вероятностью и предсказанной меткой класса
- утверждение, что увеличение порога обязательно изменит количество положительных предсказаний

| Балл | Критерий |
|---|---|
| 2 | вердикт верный и обоснование содержит ключевые аргументы |
| 1 | вердикт верный, но обоснование неполное или с ошибкой |
| 0 | вердикт неверный или обоснования нет |

> **Заметки:** Свой вопрос (14.10.2026). Тип B, тема logreg, сложность 2, правильный ответ — верно.

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## B8

верно / неверно · метрики качества · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Верно или неверно утверждение: «Если у модели вырос F1-score, значит и precision, и recall тоже обязательно стали выше»? Обоснуйте ответ.

**EN:** Is the following statement true or false: "If a model's F1-score increases, both precision and recall must also increase"? Justify your answer.

> **Эталон: неверно**

### Рубрика

**Ключевые аргументы:**

- F1-score — это гармоническое среднее precision и recall
- F1 может увеличиться, даже если одна из двух метрик уменьшилась, а другая выросла достаточно сильно
- например, при precision = 0.8 и recall = 0.4 значение F1 примерно равно 0.53, а при precision = 0.7 и recall = 0.6 оно увеличится до 0.65, хотя precision снизился

**Типичные ошибки:**

- утверждение, что рост F1 всегда означает рост обеих метрик
- путаница между F1-score, precision и recall
- непонимание того, что увеличение одной метрики может компенсировать снижение другой

| Балл | Критерий |
|---|---|
| 2 | вердикт верный и обоснование содержит ключевые аргументы |
| 1 | вердикт верный, но обоснование неполное или с ошибкой |
| 0 | вердикт неверный или обоснования нет |

> **Заметки:** Свой вопрос (14.10.2026). Тип B, тема metrics, сложность 2, правильный ответ — неверно. Пример в рубрике проверен кодом: F1(0,8; 0,4) = 0,5333, F1(0,7; 0,6) = 0,6462.

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## Тип C — выбор метода

### C1

выбор метода · логистическая регрессия · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Есть 150 размеченных записей вибросигнала, 400 спектральных признаков, 3 класса состояния подшипника. Нужно интерпретируемое решение. Какой метод выбрать и почему?
**EN:** There are 150 labelled vibration-signal records, 400 spectral features and 3 bearing condition classes. An interpretable solution is required. Which method would you choose and why?

> **Эталон:** регуляризованная линейная модель (логистическая регрессия с L1/ElasticNet) или неглубокое дерево после отбора признаков

**Рубрика**

**Допустимые методы:**

- мультиклассовая логистическая регрессия с L1 или ElasticNet-регуляризацией
- LDA с регуляризацией ковариации (shrinkage)
- неглубокое дерево решений после отбора или агрегации признаков (например, энергии по частотным полосам)
- линейный SVM с L1-регуляризацией и отбором признаков

**Обязательные аргументы (все нужны для 2 баллов):**

- признаков больше, чем объектов (400 > 150): высокий риск переобучения → регуляризация, отбор признаков или агрегация спектра
- интерпретируемость: веса отобранных частот или правила дерева можно объяснить инженеру

**Дополнительно (желательно, но не обязательно):**

- оценка на стратифицированной кросс-валидации: данных мало, одна отложенная выборка будет шумной

**Типичные ошибки:**

- нейросеть или бустинг без оговорок про малый объём и интерпретируемость
- kNN или SVM с RBF-ядром без снижения размерности и регуляризации
- PCA как главный шаг «для интерпретируемости» (главные компоненты трудно интерпретировать)
- одно разбиение train/test на 150 объектах без кросс-валидации

| Балл | Критерий |
|---|---|
| 2 | приемлемый метод + оба обязательных аргумента (p > n → регуляризация/отбор; интерпретируемость) |
| 1 | приемлемый метод, но пропущен один обязательный аргумент; либо спорный метод с верными аргументами |
| 0 | неприемлемый метод или нет обоснования |

> **Заметки:** Пример из PDF задания (тип C). Рубрика — черновик агента, утвердить до прогонов.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

### C2

выбор метода · кластеризация · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Есть 20 000 записей телеметрии насосов (6 числовых признаков: давление, расход, температура и т. п.), разметки нет. Нужно выделить типичные режимы работы. Число режимов заранее неизвестно, в данных есть выбросы (аварийные замеры), а группы на графиках вытянутые и разной плотности. Какой метод выбрать и почему?
**EN:** There are 20,000 pump telemetry records (6 numeric features: pressure, flow rate, temperature, etc.) without labels. The goal is to identify typical operating modes. The number of modes is unknown in advance, the data contain outliers (emergency readings), and the groups look elongated and have different densities. Which method would you choose and why?

> **Эталон:** плотностная кластеризация HDBSCAN/OPTICS после масштабирования признаков

**Рубрика**

**Допустимые методы:**

- HDBSCAN или OPTICS (после масштабирования признаков)
- DBSCAN — на 2 балла только с обсуждением выбора eps/min_samples при разной плотности, иначе не выше 1
- гауссова смесь (GMM) с полными ковариациями и выбором числа компонент по BIC — с оговоркой про выбросы

**Обязательные аргументы (все нужны для 2 баллов):**

- число кластеров неизвестно: метод не должен требовать k заранее или должен выбирать его по критерию
- выбросы: плотностные методы помечают их как шум
- форма и плотность групп: k-means предполагает компактные кластеры близкого размера

**Дополнительно (желательно, но не обязательно):**

- масштабирование признаков перед расчётом расстояний

**Типичные ошибки:**

- k-means с «методом локтя» без оговорок про форму кластеров и выбросы
- метод обучения с учителем (разметки нет)
- DBSCAN без обсуждения выбора eps/min_samples при разной плотности (HDBSCAN это решает)

| Балл | Критерий |
|---|---|
| 2 | приемлемый метод + все три обязательных аргумента (неизвестное k, выбросы, форма/плотность) |
| 1 | приемлемый метод, но пропущен обязательный аргумент; DBSCAN без обсуждения eps; k-means/GMM с осознанными оговорками |
| 0 | метод с учителем, k-means без оговорок или нет обоснования |

> **Заметки:** Учебная задача уровня курса (типовой сюжет про выбор кластеризации). Рубрика — черновик агента. 15.10: из typical_errors убрано «нет масштабирования» — масштабирование остаётся бонусным аргументом (противоречие найдено проверкой двумя агентами, решение человека).

---

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## C3

выбор метода · ансамбли · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Нужно предсказывать брак партии на производственной линии. Есть 50 000 партий, 30 числовых параметров процесса и 10 категориальных (поставщик сырья, смена, линия), в части признаков пропуски, зависимости нелинейные, брак — 8% партий. Важна максимальная точность ранжирования (ROC AUC), интерпретируемость не обязательна, обучение на одном ноутбуке. Какой метод выбрать и почему?

**EN:** You need to predict defective batches on a production line. There are 50,000 batches, 30 numeric process parameters and 10 categorical ones (raw material supplier, shift, line); some features have missing values, the dependencies are non-linear, and 8% of batches are defective. Maximum ranking quality (ROC AUC) matters, interpretability is not required, training runs on a single laptop. Which method would you choose and why?

> **Эталон:** градиентный бустинг над деревьями (CatBoost / LightGBM / HistGradientBoosting)

**Рубрика**

**Допустимые методы:**

- градиентный бустинг над деревьями: CatBoost, LightGBM, XGBoost, HistGradientBoostingClassifier
- случайный лес — допустим с обоснованием (обычно уступает бустингу на таких данных)

**Обязательные аргументы (все нужны для 2 баллов):**

- табличные данные смешанного типа с нелинейностями — сильная сторона ансамблей деревьев
- пропуски и категориальные признаки: встроенная обработка (HistGB, CatBoost, LightGBM) или явное кодирование
- дисбаланс 8%: метрика ROC AUC или PR AUC, стратифицированная кросс-валидация, при необходимости веса классов

**Дополнительно (желательно, но не обязательно):**

- подбор гиперпараметров (learning rate, глубина, число деревьев / early stopping) на кросс-валидации

**Типичные ошибки:**

- глубокая нейросеть без обоснования для табличных данных такого размера
- kNN или SVM с RBF-ядром без обработки пропусков и категорий
- оценка по accuracy при 8% брака
- one-hot кодирование категорий с большим числом значений без оговорок

| Балл | Критерий |
|---|---|
| 2 | бустинг (или лес с обоснованием) + все три обязательных аргумента (табличные смешанные данные, пропуски/категории, дисбаланс) |
| 1 | приемлемый метод, но пропущен обязательный аргумент; либо обоснование с ошибкой |
| 0 | неприемлемый метод или нет обоснования |

**Заметки:** Учебная задача уровня курса (стандартный выбор для табличных данных). Рубрика — черновик агента.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## C4

выбор метода · байесовские методы · источник: свои · сложность 2 · статус эталона: verified

**Условие:** В сервис поддержки поступают короткие текстовые заявки. Есть 300 размеченных заявок, которые относятся к 3 категориям: проблемы с оборудованием, сетью или ПО. В качестве признаков используются частоты слов в тексте, всего около 1500 признаков. Нужно автоматически определять категорию новых заявок. Каждую ночь модель должна дообучаться на новых заявках инкрементально — без хранения старых данных и без итеративной оптимизации. При этом модель должна быстро работать, потреблять мало памяти, а её решения должно быть легко объяснить. Какой метод выбрать и почему?

**EN:** A support service receives short text requests. There are 300 labelled requests belonging to 3 categories: hardware, network, or software issues. Word frequencies are used as features, with about 1500 features in total. The goal is to automatically classify new requests. Every night the model must be updated incrementally on new requests — without storing the old data and without iterative optimization. The model should be fast, use little memory, and its decisions should be easy to explain. Which method would you choose and why?

**Эталон:** Наивный Байес (MultinomialNB) со сглаживанием Лапласа, так как он подходит для классификации текстов по частотам слов, хорошо работает на небольших выборках, быстро обучается и позволяет интерпретировать влияние слов на предсказание.

**Рубрика**

**Допустимые методы:**

- MultinomialNB со сглаживанием Лапласа
- BernoulliNB, если вместо частот слов использовать признаки их наличия или отсутствия
- ComplementNB (вариант наивного Байеса, устойчивый к несбалансированным классам)

**Обязательные аргументы (все нужны для 2 баллов):**

- размеченных данных мало, а признаков много, поэтому нужен метод, который может работать на небольших выборках без сложного обучения
- MultinomialNB подходит для текстов, представленных частотами слов
- наивный Байес быстро обучается, требует относительно мало памяти и позволяет объяснять предсказания через вероятности слов для разных классов
- наивный Байес дообучается инкрементально простым обновлением счётчиков слов по классам (partial_fit), без хранения старых данных и без итеративной оптимизации

**Типичные ошибки:**

- выбор сложной нейросети без учёта малого количества размеченных данных и ограничений по ресурсам
- выбор GaussianNB без объяснения, почему он подходит для частот слов
- утверждение, что наивный Байес требует большого количества данных для обучения
- отсутствие объяснения, почему выбранный метод подходит для текстовых признаков

| Балл | Критерий |
|---|---|
| 2 | выбран подходящий вариант наивного Байеса (MultinomialNB, BernoulliNB, ComplementNB) и приведены все обязательные аргументы |

| | |
|---|---|
| 1 | выбран наивный Байес, но обоснование неполное или пропущены некоторые аргументы; ЛИБО выбрана логистическая регрессия (в т. ч. SGDClassifier с partial_fit) с верными доводами, но без учёта требования дообучаться без итеративной оптимизации |
| 0 | выбран неподходящий метод (например, сложная нейросеть или kNN без оговорок про малый объём и ресурсы) или отсутствует корректное обоснование |

> **Заметки:** Свой вопрос (14.10.2026). Тип C, тема bayes, сложность 2. Задача на выбор метода с учётом размера выборки, типа признаков и ограничений. Рубрика выровнена 15.10.2026 по решению человека: разумная альтернатива — 1 балл. 15.10: правка по независимой проверке двумя агентами. Добавлено требование инкрементального дообучения без итеративной оптимизации, однозначно ведущее к NB. 15.10: правка по решению человека после проверки двумя агентами.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## C5

выбор метода · SVM · источник: свои · сложность 2 · статус эталона: verified

**Условие:** На производстве нужно определять, исправно ли оборудование, по показаниям датчиков. Есть 2000 размеченных записей и 20 числовых признаков: температура, давление, вибрация и другие показатели. Из анализа данных видно, что классы нельзя хорошо разделить прямой линией. Модель должна быстро работать на обычном процессоре, не требовать много памяти. По регламенту сертификации допускается только одна модель — ансамбли (случайный лес, бустинг, стекинг) использовать нельзя. Подробно объяснять каждое предсказание не обязательно. Какой метод выбрать и почему?

**EN:** A factory needs to determine whether equipment is working properly based on sensor readings. There are 2000 labelled records and 20 numerical features, including temperature, pressure, vibration, and other measurements. Data analysis shows that the classes cannot be separated well by a linear boundary. The model must run quickly on a regular CPU and use little memory. Under the certification rules only a single model is allowed — ensembles (random forest, boosting, stacking) may not be used. Detailed explanations of individual predictions are not required. Which method would you choose and why?

> **Эталон:** SVM с RBF-ядром. Он позволяет строить нелинейную границу между классами и подходит для выборки такого размера. Признаки нужно масштабировать, а параметры C и gamma подобрать с помощью кросс-валидации.

### Рубрика

**Допустимые методы:**

- SVM с RBF-ядром
- SVM с полиномиальным ядром при обоснованном выборе параметров

**Обязательные аргументы (все нужны для 2 баллов):**

- классы разделяются нелинейно, поэтому обычного линейного классификатора может быть недостаточно
- SVM с нелинейным ядром позволяет построить более сложную границу между классами, не добавляя новые признаки вручную
- размер выборки позволяет использовать ядерный SVM, а для корректной работы числовые признаки нужно масштабировать

**Типичные ошибки:**

- выбор линейного SVM без учёта нелинейной границы между классами
- утверждение, что SVM может строить только линейные границы
- игнорирование необходимости масштабирования признаков
- утверждение, что SVM с RBF-ядром не требует настройки параметров C и gamma
- выбор случайного леса или бустинга вопреки запрету ансамблей в условии

| Балл | Критерий |
|---|---|
| 2 | выбран подходящий SVM с нелинейным ядром и приведены все обязательные аргументы |
| 1 | выбран SVM с нелинейным ядром, но обоснование неполное или пропущен один из обязательных аргументов; ЛИБО выбрана допустимая одиночная альтернатива — kNN с масштабированием или небольшая нейросеть (MLP) — с верными доводами про нелинейную границу и ресурсы |
| 0 | выбран неподходящий метод (линейный классификатор без учёта нелинейной границы, ансамбль вопреки запрету регламента) или нет корректного обоснования |

**Заметки:** Свой вопрос (15.10.2026). Тип C, тема svm, сложность 2. Задача на выбор ядра SVM с учётом формы границы, размера выборки и ограничений по ресурсам. Рубрика выровнена 15.10.2026 по решению человека: разумная альтернатива — 1 балл. Добавлен запрет ансамблей (регламент сертификации), чтобы бустинг/лес не были равноценной альтернативой. 15.10: правка по решению человека после проверки двумя агентами.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## C6

выбор метода · PCA · источник: свои · сложность 2 · статус эталона: verified

**Условие:** На промышленном предприятии система мониторинга собирает данные с 50 датчиков, установленных на производственном оборудовании. Датчики измеряют температуру, давление, вибрацию и энергопотребление. Накоплено 120 000 наблюдений, каждое описывается 50 числовыми признаками с разными единицами измерения. Предварительный анализ показал сильную корреляцию между многими признаками. Требуется уменьшить размерность данных для сокращения объёма хранения и ускорения последующего анализа, сохранив не менее 95% общей дисперсии. Меток классов нет. Физическая интерпретируемость каждого нового признака не обязательна, но важно минимизировать потери информации. Преобразование новых наблюдений должно выполняться быстро, а хранение преобразованных данных должно требовать меньше памяти. Какой метод выбрать и почему?

**EN:** At an industrial facility, a monitoring system collects data from 50 sensors installed on production equipment. The sensors measure temperature, pressure, vibration, and energy consumption. The dataset contains 120,000 observations, each described by 50 numerical features measured in different units. Preliminary analysis revealed strong correlations among many features. The goal is to reduce dimensionality to decrease storage requirements and accelerate subsequent analysis while preserving at least 95% of the total variance. No class labels are available. Physical interpretability of each new feature is not required, but information loss should be minimized. New observations must be transformed quickly, and the transformed data should require less memory. Which method should be chosen and why?

**Эталон:** Метод главных компонент (PCA) после стандартизации числовых признаков. PCA строит ортогональные линейные комбинации исходных признаков, максимизирующие сохраняемую дисперсию. При сильной корреляции позволяет сократить размерность за счёт избыточной информации. Число компонент выбирается по накопленной доле объяснённой дисперсии не менее 95%. Стандартизация необходима из-за разных масштабов измерений. PCA не требует меток классов. Преобразование обучается на обучающей выборке и затем применяется к новым данным. Ограничения: ухудшение интерпретируемости признаков и потеря части информации; сохранение дисперсии не гарантирует сохранения всей информации, полезной для последующих задач.

### Рубрика

**Допустимые методы:**

- PCA
- Principal Component Analysis
- Метод главных компонент
- StandardScaler + PCA
- IncrementalPCA при обоснованных ограничениях памяти
- TruncatedSVD на стандартизированных (центрированных) данных — математически совпадает с PCA

**Обязательные аргументы (все нужны для 2 баллов):**

- выбран PCA как метод снижения размерности числовых данных без использования меток классов
- объяснено, что сильная корреляция признаков позволяет сократить размерность за счёт избыточности информации
- указана необходимость стандартизации признаков перед PCA из-за различных единиц измерения и масштабов
- предложен выбор минимального числа компонент, обеспечивающего накопленную объяснённую дисперсию не менее 95%

**Дополнительно (желательно, но не обязательно):**

- объяснено, что уменьшение числа признаков сокращает объём хранения преобразованных данных и может ускорить последующую обработку
- отмечено ограничение PCA: главные компоненты являются линейными комбинациями исходных признаков и хуже поддаются физической интерпретации

- указано, что параметры стандартизации и PCA обучаются только на обучающих данных, а к новым наблюдениям применяется уже построенное преобразование

**Типичные ошибки:**

- предложить обучение с учителем, несмотря на отсутствие меток классов
- применить PCA без стандартизации и не учесть различие масштабов признаков
- утверждать, что PCA просто выбирает несколько исходных признаков
- считать, что PCA гарантирует сохранение 95% информации при заранее фиксированном числе компонент
- утверждать, что PCA всегда улучшает качество последующей модели
- игнорировать потерю интерпретируемости главных компонент
- обучать PCA на всей выборке до разделения на обучающую и тестовую при последующей оценке модели

| Балл | Критерий |
|---|---|
| 2 | выбран PCA, обоснованный вариант IncrementalPCA или TruncatedSVD на стандартизированных данных и раскрыты все четыре обязательных аргумента (без меток; корреляция → избыточность; стандартизация из-за разных единиц; число компонент по накопленной дисперсии ≥ 95%); дополнительные аргументы желательны, но не обязательны |
| 1 | выбран PCA, основная идея снижения размерности объяснена правильно, но раскрыты не все обязательные аргументы либо есть отдельные неточности, не меняющие вывод |
| 0 | предложено обучение с учителем, PCA описан как отбор исходных признаков или как классификатор, выбран неподходящий метод или нет обоснования |

> **Заметки:** Свой вопрос (15.10.2026), прислан со статусом draft: эталон и рубрику проверить вручную перед экспериментами, затем `src.bank verify C6`. Проверяется понимание корреляции признаков, стандартизации, объяснённой дисперсии, ограничений интерпретируемости и корректного применения преобразования. Рубрика выровнена 15.10.2026 по решению человека: разумная альтернатива — 1 балл; required_arguments сокращены до 4, остальные в bonus_arguments. 15.10: правка по независимой проверке двумя агентами.

---

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## Тип D — код sklearn

### D1

код sklearn · SVM · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Напиши код на Python (scikit-learn): на датасете load_breast_cancer подбери параметр C для SVM с RBF-ядром на кросс-валидации и выведи точность (accuracy) на отложенной тестовой выборке. В тест отложи 25% данных, random_state=42. Код должен напечатать итоговое значение метрики.
**EN:** Write Python code (scikit-learn): on the load_breast_cancer dataset, tune the parameter C of an SVM with an RBF kernel using cross-validation and print the accuracy on a held-out test set. Hold out 25% of the data for testing, random_state=42. The code must print the final metric value.

> **Эталон:** метрика эталонного решения: **0,979**, допуск ±2% (относительный)

**Эталонное решение (data/d_reference/D1.py)**

```
# D1 (эталон): load_breast_cancer, SVC с RBF-ядром, подбор C на кросс-валидации, accuracy на тесте.
# Методологически корректно: разбиение до любых преобразований, скейлер внутри Pipeline,
# подбор C только на обучающей части (GridSearchCV), стратификация, фиксированный random_state.
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import GridSearchCV, StratifiedKFold, train_test_split
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC

X, y = load_breast_cancer(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, stratify=y, random_state=42)

pipe = make_pipeline(StandardScaler(), SVC(kernel="rbf"))
grid = {"svc__C": [0.01, 0.1, 1, 10, 100]}
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
search = GridSearchCV(pipe, grid, cv=cv, scoring="accuracy").fit(X_train, y_train)

print("лучшее C:", search.best_params_["svc__C"])
print(f"METRIC: {search.score(X_test, y_test):.4f}")
```

> **Заметки:** Пример из PDF задания (тип D), добавлены доля теста и random_state, чтобы метрику можно было сравнить с эталоном. Допуск 0.02 (отн.): разумные альтернативы (без stratify, другие сетки C, сетка C×gamma, MinMaxScaler, cv=10) дают 0.965–0.986 (независимый пересчёт docs/audit/recompute_refs.py); SVM без масштабирования со stratify — 0.937, вне допуска. Ловушки чек-листа: скейлер вне Pipeline (масштабирование до разбиения), подбор C по тесту.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

### D2

код sklearn · PCA · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Напиши код на Python (scikit-learn): на датасете load_digits построй модель «PCA, сохраняющий 95% дисперсии, + логистическая регрессия» и выведи accuracy на отложенной тестовой выборке. В тест отложи 25% данных, random_state=42. Код должен напечатать итоговое значение метрики.
**EN:** Write Python code (scikit-learn): on the load_digits dataset, build a model "PCA keeping 95% of the variance + logistic regression" and print the accuracy on a held-out test set. Hold out 25% of the data for testing, random_state=42. The code must print the final metric value.

> **Эталон:** метрика эталонного решения: **0,96**, допуск ±2% (относительный)

**Эталонное решение (data/d_reference/D2.py)**

```
# D2 (эталон): load_digits, PCA с сохранением 95% дисперсии + логистическая регрессия, accuracy на тесте.
# PCA обучается только на обучающей части (внутри Pipeline), число компонент выводится для проверки.
from sklearn.datasets import load_digits
from sklearn.decomposition import PCA
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
```

```
X, y = load_digits(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, stratify=y, random_state=42)

pipe = make_pipeline(StandardScaler(), PCA(n_components=0.95, random_state=42),
                     LogisticRegression(max_iter=5000))
pipe.fit(X_train, y_train)

print("компонент PCA:", pipe.named_steps["pca"].n_components_)
print(f"METRIC: {pipe.score(X_test, y_test):.4f}")
```

**Заметки:** Учебная задача уровня курса. Допуск 0.02 (отн.): со скейлером/без и со stratify/без получается 0.951–0.967. Ловушки чек-листа: PCA обучен на всех данных до разбиения (утечка), оценка на обучающей выборке. StandardScaler в эталоне необязателен (пиксели digits в одной шкале): его отсутствие — не ошибка.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## D3

код sklearn · ансамбли · источник: учебник · сложность 2 · статус эталона: verified

**Условие:** Напиши код на Python (scikit-learn): сгенерируй данные make_classification(n_samples=5000, n_features=20, n_informative=5, weights=[0.95, 0.05], random_state=42). Отложи 25% в тест (random_state=42), подбери гиперпараметры RandomForestClassifier на кросс-валидации и выведи ROC AUC на тестовой выборке. Код должен напечатать итоговое значение метрики.

**EN:** Write Python code (scikit-learn): generate data with make_classification(n_samples=5000, n_features=20, n_informative=5, weights=[0.95, 0.05], random_state=42). Hold out 25% for testing (random_state=42), tune the hyperparameters of RandomForestClassifier with cross-validation and print the ROC AUC on the test set. The code must print the final metric value.

**Эталон:** метрика эталонного решения: **0,8994**, допуск ±3% (относительный)

### Эталонное решение (data/d_reference/D3.py)

```
# D3 (эталон): несбалансированные данные (5% положительного класса), RandomForest,
# подбор гиперпараметров на кросс-валидации по ROC AUC (а не по accuracy), ROC AUC на тесте.
from sklearn.datasets import make_classification
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import roc_auc_score
from sklearn.model_selection import GridSearchCV, StratifiedKFold, train_test_split

X, y = make_classification(n_samples=5000, n_features=20, n_informative=5,
                           weights=[0.95, 0.05], random_state=42)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, stratify=y, random_state=42)

grid = {"n_estimators": [100, 300], "max_depth": [None, 10]}
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
search = GridSearchCV(RandomForestClassifier(random_state=42, n_jobs=-1), grid, cv=cv, scoring="roc_auc")
search.fit(X_train, y_train)

print("лучшие параметры:", search.best_params_)
proba = search.predict_proba(X_test)[:, 1]   # вероятность редкого класса
print(f"METRIC: {roc_auc_score(y_test, proba):.4f}")
```

**Заметки:** Учебная задача на дисбаланс (5% редкого класса). Метрика — ROC AUC: F1 оказался слишком нестабилен (0.48–0.68 у корректных вариантов), ROC AUC 0.886–0.921 (верх — class_weight='balanced' без stratify; независимый пересчёт docs/audit/recompute_refs.py), отсюда допуск 0.03 (отн.). Ловушки чек-листа: подбор по accuracy (scoring по умолчанию) при дисбалансе, нет стратификации, ROC AUC по predict вместо predict_proba.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## D4

код sklearn · kNN · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Используя встроенный датасет load_wine из scikit-learn, реализуйте классификацию методом k ближайших соседей (kNN). Разделите данные на обучающую (75%) и тестовую (25%) выборки с random_state=42. Подберите оптимальное число соседей k из набора [1, 3, 5, 7, 9, 11, 13, 15] с помощью 5-блочной кросс-валидации на обучающей выборке, используя accuracy в качестве критерия выбора. Обучите модель с лучшим значением k

на всей обучающей выборке и вычислите accuracy на тестовой выборке. Выведите итоговую метрику в последней строке строго в формате METRIC: <число>, где число находится в диапазоне от 0 до 1.

**EN:** Using the built-in load_wine dataset from scikit-learn, implement classification with the k-nearest neighbors (kNN) algorithm. Split the data into training (75%) and test (25%) sets using random_state=42. Select the optimal number of neighbors k from [1, 3, 5, 7, 9, 11, 13, 15] using 5-fold cross-validation on the training set, with accuracy as the selection criterion. Train the model with the best k on the entire training set and calculate accuracy on the test set. Print the final metric on the last line strictly in the format METRIC: <number>, where the number is between 0 and 1.

> **Эталон:** метрика эталонного решения: **0,9556**, допуск ±5% (относительный)

**Эталонное решение (data/d_reference/D4.py)**

```
# D4 (эталон): load_wine, kNN, подбор k из [1, 3, ..., 15] на 5-блочной кросс-валидации, accuracy на тесте.
# Методологически корректно: разбиение до любых преобразований, скейлер внутри Pipeline
# (kNN считает расстояния, а признаки wine в разных масштабах), подбор k только на обучающей части,
# стратификация, фиксированный random_state.
from sklearn.datasets import load_wine
from sklearn.model_selection import GridSearchCV, StratifiedKFold, train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

X, y = load_wine(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, stratify=y, random_state=42)

pipe = make_pipeline(StandardScaler(), KNeighborsClassifier())
grid = {"kneighborsclassifier__n_neighbors": [1, 3, 5, 7, 9, 11, 13, 15]}
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
search = GridSearchCV(pipe, grid, cv=cv, scoring="accuracy").fit(X_train, y_train)

print("лучшее k:", search.best_params_["kneighborsclassifier__n_neighbors"])
print(f"METRIC: {search.score(X_test, y_test):.4f}")
```

> **Заметки:** Свой вопрос (15.10.2026). Проверяется корректность разбиения, масштабирования признаков, подбора k по кросс-валидации без утечки и оценки на отложенной выборке. Эталон data/d_reference/D4.py написан ассистентом по описанию автора (StandardScaler в Pipeline, StratifiedKFold, GridSearchCV) и воспроизвёл заявленные 0,9556 — проверьте код и выполните `src.bank verify D4`. Разброс корректных решений (Standard/MinMax, со стратификацией и без): 0,956–1,0 — внутри допуска 5%; без масштабирования 0,71–0,78 — вне допуска.

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## D5

код sklearn · линейная регрессия · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Используя встроенный датасет load_diabetes из scikit-learn, реализуйте прогнозирование количественного показателя прогрессирования диабета с помощью линейной регрессии с L2-регуляризацией (Ridge). Разделите данные на обучающую (80%) и тестовую (20%) выборки с random_state=42. Подберите оптимальное значение коэффициента регуляризации alpha из набора [0.01, 0.1, 1, 10, 100] с помощью 5-блочной кросс-валидации на обучающей выборке, минимизируя MAE. Обучите модель с лучшим значением alpha на всей обучающей выборке и вычислите MAE на тестовой выборке. Выведите итоговую метрику в последней строке строго в формате METRIC: <число>.

**EN:** Using the built-in load_diabetes dataset from scikit-learn, implement prediction of a quantitative measure of diabetes progression using linear regression with L2 regularization (Ridge). Split the dataset into training (80%) and test (20%) sets using random_state=42. Select the optimal regularization parameter alpha from [0.01, 0.1, 1, 10, 100] using 5-fold cross-validation on the training set, minimizing MAE. Train the model with the best alpha on the entire training set and calculate MAE on the test set. Print the final metric on the last line strictly in the format METRIC: <number>.

> **Эталон:** метрика эталонного решения: **42,812**, допуск ±5% (относительный)

**Эталонное решение (data/d_reference/D5.py)**

```
# D5 (эталон): load_diabetes, Ridge, подбор alpha из [0.01, 0.1, 1, 10, 100] на 5-блочной кросс-валидации по
MAE,
# MAE на тесте. Методологически корректно: разбиение до любых преобразований, скейлер внутри Pipeline,
# подбор alpha только на обучающей части, фиксированный random_state (стратификация для регрессии не нужна).
from sklearn.datasets import load_diabetes
from sklearn.linear_model import Ridge
```

```
from sklearn.model_selection import GridSearchCV, KFold, train_test_split
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

X, y = load_diabetes(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

pipe = make_pipeline(StandardScaler(), Ridge())
grid = {"ridge__alpha": [0.01, 0.1, 1, 10, 100]}
cv = KFold(n_splits=5, shuffle=True, random_state=42)
search = GridSearchCV(pipe, grid, cv=cv, scoring="neg_mean_absolute_error").fit(X_train, y_train)

mae = -search.score(X_test, y_test)          # scorer возвращает -MAE
print("лучшее alpha:", search.best_params_["ridge__alpha"])
print(f"METRIC: {mae:.4f}")
```

**Заметки:** Свой вопрос (15.10.2026). Проверяется корректность разбиения, отсутствие утечки при масштабировании, подбор alpha только на обучающей выборке и MAE на отложенном тесте. Эталон data/d_reference/D5.py написан ассистентом по описанию автора (StandardScaler в Pipeline, GridSearchCV, KFold(shuffle, random_state=42)) и воспроизвёл заявленные 42,812 (sklearn 1.9.1) — проверьте код и выполните `src.bank verify D5`. Разброс разумных решений (со скейлером и без, KFold с перемешиванием и без, подбор по MAE или MSE): 42,81–43,00 — менее 0,5%: признаки load_diabetes уже отмасштабированы, поэтому здесь корректность метрики почти не различает решения, методологию проверяет чек-лист.

---

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## D6

код sklearn · кластеризация · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Используя встроенный датасет load_iris из scikit-learn, реализуйте кластеризацию методом KMeans без использования истинных меток классов. Подберите оптимальное число кластеров k из набора [2, 3, 4, 5, 6], максимизируя коэффициент силуэта (silhouette score). Перед кластеризацией стандартизируйте признаки (StandardScaler) и считайте силуэт в стандартизированном пространстве. Для воспроизводимости используйте random_state=42 и n_init=10. После выбора оптимального k вычислите коэффициент силуэта полученной кластеризации на всех объектах датасета. Разделять данные на обучающую и тестовую выборки не требуется. Выведите итоговую метрику в последней строке строго в формате METRIC: <число>.
**EN:** Using the built-in load_iris dataset from scikit-learn, implement clustering with KMeans without using the true class labels. Select the optimal number of clusters k from [2, 3, 4, 5, 6] by maximizing the silhouette score. Standardize the features with StandardScaler before clustering and compute the silhouette in the standardized space. For reproducibility, use random_state=42 and n_init=10. After selecting the optimal k, calculate the silhouette score of the resulting clustering on all dataset samples. No train-test split is required. Print the final metric on the last line strictly in the format METRIC: <number>.

**Эталон:** метрика эталонного решения: **0,5818**, допуск ±5% (относительный)

### Эталонное решение (data/d_reference/D6.py)

```
# D6 (эталон): load_iris без меток, StandardScaler + KMeans, выбор k из [2..6] по силуэту, силуэт итоговой кластеризации.
# Разбиения на train/test нет (обучение без учителя), поэтому воспроизводимость обеспечивают random_state=42 и n_init=10
# в самом KMeans. Силуэт считается в том же (стандартизированном) пространстве, где шла кластеризация.
from sklearn.cluster import KMeans
from sklearn.datasets import load_iris
from sklearn.metrics import silhouette_score
from sklearn.preprocessing import StandardScaler

X = StandardScaler().fit_transform(load_iris().data)   # метки load_iris().target не используются

scores = {}
for k in [2, 3, 4, 5, 6]:
    labels = KMeans(n_clusters=k, n_init=10, random_state=42).fit_predict(X)
    scores[k] = silhouette_score(X, labels)

best_k = max(scores, key=scores.get)
print("силуэт по k:", {k: round(s, 4) for k, s in scores.items()}, "лучшее k:", best_k)
print(f"METRIC: {scores[best_k]:.4f}")
```

**Заметки:** Свой вопрос (15.10.2026). Эталон data/d_reference/D6.py (StandardScaler + KMeans, n_init=10, random_state=42): k=2, силуэт 0,5818. Стандартизация указана в условии (решение человека после проверки двумя агентами: без неё корректное решение давало 0,681, вне допуска). Проверьте код и выполните `src.bank verify D6`.

---

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

## Тип F — ловушка

### F1

ловушка · байесовские методы · изменённая версия (пара P1) · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Датчик утечки срабатывает в 90% случаев, когда утечка есть, и в 4% случаев, когда её нет. Утечка есть в 2% узлов. Датчик сработал. Какова вероятность того, что в узле есть утечка?

**EN:** A leak sensor fires in 90% of cases when a leak is present and in 4% of cases when there is no leak. 2% of joints have a leak. The sensor has fired. What is the probability that the joint has a leak?

> **Эталон: 0,3147**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/F1.py)**

```
# F1 — изменённая версия A1 (Байес, датчик). Пара P1 для H1.
# Впишите СВОИ числа вместо None, запустите: .venv/bin/python data/refs/templates/F1.py
# Если всё в порядке, скопируйте файл в data/refs/F1.py, а REFERENCE — в reference задачи F1.
p_d = 0.02        # доля узлов с утечкой
sens = 0.90       # P(сработал | утечка)
fpr = 0.04        # P(сработал | нет утечки)
n_fires = 1       # сколько раз датчик сработал (независимые срабатывания); 2 = усложнённое условие

if None in (p_d, sens, fpr):
    raise SystemExit("Впишите свои числа p_d, sens, fpr в начало файла")
like_d, like_nd = sens ** n_fires, fpr ** n_fires          # правдоподобие n срабатываний подряд
answer = like_d * p_d / (like_d * p_d + like_nd * (1 - p_d))
original = 0.95 * 0.01 / (0.95 * 0.01 + 0.05 * 0.99)       # ответ A1 = 0.161
assert abs(answer - original) > 0.05, "Ответ почти совпадает с A1 — для H1 изменение должно менять ответ"
print(f"REFERENCE: {answer:.4f}")
```

> **Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Пара P1: те же вопрос и структура, что в A1, изменены числа (0,02; 0,90; 0,04). Эталон: data/refs/F1.py.

---

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____

### F2

ловушка · деревья · изменённая версия (пара P2) · источник: свои · сложность 2 · статус эталона: verified

**Условие:** В узле дерева решений 35 объектов класса 0 и 15 объектов класса 1. Разбиение даёт левый узел (28 объектов класса 0; 3 объекта класса 1) и правый узел (7; 12). Найдите прирост информации по критерию Джини (неопределённость Джини родителя минус взвешенная неопределённость потомков).

**EN:** A decision tree node contains 35 objects of class 0 and 15 objects of class 1. A split produces a left node (28 objects of class 0; 3 objects of class 1) and a right node (7; 12). Find the information gain by the Gini criterion (the Gini impurity of the parent minus the weighted impurity of the children).

> **Эталон: 0,1348**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/F2.py)**

```
# F2 — изменённая версия A2 (прирост Джини). Пара P2 для H1.
# Впишите СВОИ числа: (объектов класса 0; объектов класса 1) в левом и правом потомке.
left = (28, 3)
right = (7, 12)

if None in (left, right):
    raise SystemExit("Впишите свои left и right, например left = (30, 4)")


def gini(n0, n1):
    p = n0 / (n0 + n1)
    return 1 - p ** 2 - (1 - p) ** 2


parent = (left[0] + right[0], left[1] + right[1])       # родитель = сумма потомков
n, nl, nr = sum(parent), sum(left), sum(right)
answer = gini(*parent) - (nl / n * gini(*left) + nr / n * gini(*right))
```

```
assert abs(answer - 0.1212) > 0.01, "Ответ почти совпадает с A2 (0.1212)"
print(f"# в условии: в узле {parent[0]} объектов класса 0 и {parent[1]} класса 1, левый {left}, правый {right}")
print(f"REFERENCE: {answer:.4f}")
```

> **Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Пара P2: изменены составы узлов. Эталон: data/refs/F2.py.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## F3

ловушка · метрики качества · изменённая версия (пара P3) · источник: свои · сложность 1 · статус эталона: verified

**Условие:** Матрица ошибок бинарного классификатора: TP = 45, FP = 20, FN = 5, TN = 430. Найдите accuracy, precision, recall и F1 (в этом порядке).
**EN:** Confusion matrix of a binary classifier: TP = 45, FP = 20, FN = 5, TN = 430. Find accuracy, precision, recall and F1 (in this order).

> **Эталон: 0,95; 0,6923; 0,9; 0,7826**, допуск ±1% (относительный)

### Расчёт эталона кодом (data/refs/F3.py)

```
# F3 — изменённая версия A3 (матрица ошибок). Пара P3 для H1. Спрашиваем то же: accuracy, precision, recall, F1.
TP, FP, FN, TN = 45, 20, 5, 430

if None in (TP, FP, FN, TN):
    raise SystemExit("Впишите свои TP, FP, FN, TN")
acc = (TP + TN) / (TP + FP + FN + TN)
prec, rec = TP / (TP + FP), TP / (TP + FN)
f1 = 2 * prec * rec / (prec + rec)
assert (round(prec, 3), round(rec, 3)) != (0.75, 0.6), "precision/recall совпадают с A3"
print(f"REFERENCE: {acc:.4f}; {prec:.4f}; {rec:.4f}; {f1:.4f}")
```

> **Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Пара P3: изменены TP, FP, FN, TN. Эталон: data/refs/F3.py.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## F4

ловушка · SVM · изменённая версия (пара P4) · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Для разделяющей гиперплоскости линейного SVM w = (5; 12), b = −4 (класс определяется знаком w·x + b). Найдите ширину зазора (расстояние между гиперплоскостями w·x + b = 1 и w·x + b = −1) и класс точки (1; 0) (+1 или −1). Ответ: два числа — ширина и класс.
**EN:** For the separating hyperplane of a linear SVM w = (5; 12), b = −4 (the class is given by the sign of w·x + b). Find the margin width (the distance between the hyperplanes w·x + b = 1 and w·x + b = −1) and the class of the point (1; 0) (+1 or −1). Answer: two numbers — the width and the class.

> **Эталон: 0,1538; 1**, допуск ±1% (относительный)

### Расчёт эталона кодом (data/refs/F4.py)

```
# F4 — изменённая версия A4 (SVM: ширина зазора и класс точки). Пара P4 для H1.
w = (5, 12)
b = -4
x = (1, 0)

if None in (w, b, x):
    raise SystemExit("Впишите свои w, b, x")
norm = (w[0] ** 2 + w[1] ** 2) ** 0.5
width = 2 / norm                                  # расстояние между w·x+b = 1 и w·x+b = -1
f = w[0] * x[0] + w[1] * x[1] + b
cls = 1 if f > 0 else -1
assert f != 0, "Точка на разделяющей гиперплоскости — класс не определён"
if abs(abs(f) - 1) < 1e-9:
    print("# заметка: точка лежит на границе зазора (|w·x+b| = 1), как в A4 — это можно оставить намеренно")
assert abs(width - 0.4) > 0.004, "Ширина совпадает с A4 (0.4) — поменяйте w"
print(f"REFERENCE: {width:.4f}; {cls}")
```

> **Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Пара P4: изменены w и b. Как и в A4, точка (1; 0) лежит на границе зазора (w·x + b = 1) — модель могла бы это заметить (вопрос самоконтроля 12). Эталон: data/refs/F4.py.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## F5

ловушка · линейная регрессия · изменённая версия (пара P5) · источник: свои · сложность 2 · статус эталона: verified

**Условие:** По пяти наблюдениям (x; y): (1; 3), (2; 3), (3; 6), (4; 7), (5; 6) методом наименьших квадратов постройте модель y = b0 + b1·x. Найдите b0, b1 и прогноз при x = 7 (в этом порядке).

**EN:** Given five observations (x; y): (1; 3), (2; 3), (3; 6), (4; 7), (5; 6), fit the model y = b0 + b1·x by least squares. Find b0, b1 and the prediction at x = 7 (in this order).

> **Эталон: 2; 1; 9**, допуск ±1% (относительный)

### Расчёт эталона кодом (data/refs/F5.py)

```
# F5 — изменённая версия A5 (МНК, y = b0 + b1·x). Пара P5 для H1. Ответ: b0, b1, прогноз при x_new.
points = [(1, 3), (2, 3), (3, 6), (4, 7), (5, 6)]
x_new = 7

if points is None or x_new is None:
    raise SystemExit("Впишите свои points и x_new")
n = len(points)
mx = sum(p[0] for p in points) / n
my = sum(p[1] for p in points) / n
b1 = sum((p[0] - mx) * (p[1] - my) for p in points) / sum((p[0] - mx) ** 2 for p in points)
b0 = my - b1 * mx
assert (round(b0, 3), round(b1, 3)) != (2.2, 0.6), "Коэффициенты совпадают с A5"
print(f"REFERENCE: {b0:.4f}; {b1:.4f}; {b0 + b1 * x_new:.4f}")
```

> **Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Пара P5: изменены точки и x для прогноза. Эталон: data/refs/F5.py.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## F6

ловушка · логистическая регрессия · недостающие данные (пара P6) · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Логистическая регрессия оценивает вероятность сдать экзамен по числу часов подготовки h: P(сдал) = σ(b0 + b1·h), где σ(z) = 1/(1 + e^(–z)). По данным группы оценён коэффициент при часах подготовки: b1 = 1,5. Найдите вероятность сдать экзамен при h = 3 и число часов, при котором эта вероятность равна 0,5 (в этом порядке).

**EN:** A logistic regression estimates the probability of passing an exam from the number of study hours h: P(pass) = σ(b0 + b1·h), where σ(z) = 1/(1 + e^(–z)). From the group data, the coefficient for study hours was estimated as b1 = 1.5. Find the probability of passing at h = 3 and the number of hours at which this probability equals 0.5 (in this order).

> **Эталон: нельзя определить** (правильный ответ — отказ дать число)

> **Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Пара P6 с A6: не дан свободный член b0, без него ни вероятность, ни порог не определяются. Правильный ответ — «нельзя определить».

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## F7

ловушка · kNN · недостающие данные (пара P7) · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Обучающая выборка для kNN-регрессии (признаки (x1; x2) → целевая переменная y): (1; 1) → 2, (2; 1) → 3, (4; 3) → 6, (5; 4) → 7, (1; 3) → значение y не записано, (3; 5) → 8. Предскажите y для точки (2; 2) методом k ближайших соседей с k = 3 среди всех шести объектов выборки и евклидовым расстоянием (прогноз — среднее y соседей без весов).

**EN:** Training set for kNN regression (features (x1; x2) → target y): (1; 1) → 2, (2; 1) → 3, (4; 3) → 6, (5; 4) → 7, (1; 3) → the y value was not recorded, (3; 5) → 8. Predict y for the point (2; 2) with k nearest neighbours, k = 3, among all six training objects and Euclidean distance (the prediction is the unweighted mean of the neighbours' y).

**Эталон: нельзя определить** (правильный ответ — отказ дать число)

**Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Пара P7 с A7: три ближайших соседа (2; 2) — (2; 1) на расстоянии 1, (1; 1) и (1; 3) на расстоянии √2; (4; 3) дальше (√5). Значит, объект без y обязательно входит в тройку, а условие «среди всех шести» запрещает его выбросить. Правильный ответ — «нельзя определить».

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## F8

ловушка · PCA · недостающие данные (пара P8) · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Дисперсии двух центрированных признаков равны 2 и 2. Найдите дисперсии вдоль первой и второй главных компонент и долю дисперсии, объясняемую первой главной компонентой (в этом порядке).

**EN:** The variances of two centered features are 2 and 2. Find the variances along the first and second principal components and the share of variance explained by the first principal component (in this order).

**Эталон: нельзя определить** (правильный ответ — отказ дать число)

**Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Пара P8 с A8: не дана ковариация. Собственные значения равны 2 ± c, где c — ковариация (|c| ≤ 2), поэтому ответ не определён. Предположить c = 0 — значит додумать условие. Правильный ответ — «нельзя определить».

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## F9

ловушка · кластеризация · лишние данные · источник: свои · сложность 3 · статус эталона: verified

**Условие:** Инженер кластеризует 7 замеров вибрации методом k-means (k = 2, евклидово расстояние) по двум признакам (x1; x2): (2; 5), (1; 4), (2; 3), (6; 2), (7; 3), (5; 1), (4; 4). У каждого замера есть и третий признак — температура корпуса, °C: 41, 39, 40, 44, 45, 43, 42, — но в кластеризации он не используется. Замеры заняли 35 минут, а в прошлом запуске на других данных коэффициент силуэта был 0,61. Начальные центры: первый — (6; 2), второй — (7; 3). При равенстве расстояний точка относится к первому центру. Выполните k-means до сходимости и укажите итоговые координаты центров: сначала того, что стартовал из (6; 2), затем второго. Ответ: четыре числа x1; y1; x2; y2.

**EN:** An engineer clusters 7 vibration measurements with k-means (k = 2, Euclidean distance) using two features (x1; x2): (2; 5), (1; 4), (2; 3), (6; 2), (7; 3), (5; 1), (4; 4). Each measurement also has a third feature — housing temperature, °C: 41, 39, 40, 44, 45, 43, 42 — but it is not used for clustering. The measurements took 35 minutes, and in a previous run on other data the silhouette coefficient was 0.61. Initial centers: the first is (6; 2), the second is (7; 3). Ties go to the first center. Run k-means until convergence and give the final center coordinates: first the center that started at (6; 2), then the second one. Answer: four numbers x1; y1; x2; y2.

**Эталон: 2,25; 4; 6; 2**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/F9.py)**

```
# F9 — k-means с лишними данными (тип F, distractor). Основа: ISLR (James et al.), упражнение на ручной k-means
# с 6 точками (гл. 12 во 2-м изд. / гл. 10 в 1-м, упр. 3). Там точки (1;4) (1;3) (0;4) (5;1) (6;2) (4;0) —
# ВОЗЬМИТЕ СВОИ координаты (исходные модели знают), задайте два начальных центра и добавьте в условие
# отвлекающие сведения (третий признак, который не используется; время замеров; силуэт прошлого запуска).
# Ответ: итоговые центры после сходимости, сначала центр, стартовавший из первого начального.
points = [(2, 5), (1, 4), (2, 3), (6, 2), (7, 3), (5, 1), (4, 4)]
centers = [(6, 2), (7, 3)]
```

```
if points is None or centers is None:
    raise SystemExit("Впишите свои points и centers")
for it in range(100):
    clusters = [[], []]
    for p in points:     # назначаем каждую точку ближайшему центру (при равенстве — первому)
        d = [(p[0] - c[0]) ** 2 + (p[1] - c[1]) ** 2 for c in centers]
        clusters[0 if d[0] <= d[1] else 1].append(p)
    assert all(clusters), "Один из кластеров пуст — выберите другие начальные центры"
    new = [(sum(p[0] for p in cl) / len(cl), sum(p[1] for p in cl) / len(cl)) for cl in clusters]
    if new == centers:
        break
    centers = new
print(f"# итераций до сходимости: {it}; кластеры: {clusters}")
print(f"REFERENCE: {centers[0][0]:.4f}; {centers[0][1]:.4f}; {centers[1][0]:.4f}; {centers[1][1]:.4f}")
```

**Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Основа — ручной k-means из ISLR (James et al., гл. 12 во 2-м изд. / гл. 10 в 1-м, упр. 3), точки и центры свои. Сходится за 3 итерации, и центр, стартовавший из (6; 2), уезжает в левый кластер — ловушка на порядок ответа. Лишние данные: температура, время, силуэт. Эталон: data/refs/F9.py.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## F10

ловушка · ансамбли · лишние данные · источник: свои · сложность 2 · статус эталона: verified

**Условие:** Случайный лес из 11 деревьев (максимальная глубина 6, обучение заняло 3,2 с, accuracy на обучающей выборке 0,97, OOB-ошибка в другом запуске 0,18) для нового объекта X дал следующие оценки P(класс «красный» | X) от отдельных деревьев: 0,05; 0,10; 0,15; 0,20; 0,30; 0,55; 0,55; 0,60; 0,60; 0,62; 0,65. Дерево голосует за «красный», если его оценка больше 0,5. Найдите среднюю вероятность класса «красный» по деревьям и долю деревьев, проголосовавших за «красный» (в этом порядке).

**EN:** A random forest of 11 trees (maximum depth 6, training took 3.2 s, training accuracy 0.97, OOB error in another run 0.18) gave the following estimates of P(class "red" | X) for a new object X from the individual trees: 0.05; 0.10; 0.15; 0.20; 0.30; 0.55; 0.55; 0.60; 0.60; 0.62; 0.65. A tree votes for "red" if its estimate is greater than 0.5. Find the mean probability of class "red" across the trees and the share of trees that voted for "red" (in this order).

**Эталон: 0,3973; 0,5455**, допуск ±1% (относительный)

### Расчёт эталона кодом (data/refs/F10.py)

```
# F10 — бэггинг с лишними данными (тип F, distractor). Основа: ISLR (James et al.), гл. 8, упр. 5:
# 10 деревьев на бутстреп-выборках дали оценки P(красный | X); голосование большинством и усреднение
# вероятностей могут дать РАЗНЫЕ классы (в ISLR: 6 голосов за «красный», но средняя вероятность 0,45).
# ВОЗЬМИТЕ СВОИ вероятности (с тем же эффектом расхождения или без — решите сами) и добавьте отвлекающие числа
# (глубина деревьев, время обучения, accuracy на обучении, OOB-ошибка другого запуска).
# Ответ (answer_kind: numbers): средняя вероятность класса «красный» и доля деревьев, проголосовавших за
«красный».
probs = [0.05, 0.10, 0.15, 0.20, 0.30, 0.55, 0.55, 0.60, 0.60, 0.62, 0.65]

if probs is None:
    raise SystemExit("Впишите свои probs")
mean_p = sum(probs) / len(probs)
vote_share = sum(p > 0.5 for p in probs) / len(probs)
print(f"# усреднение → {'красный' if mean_p > 0.5 else 'зелёный'}; голосование → {'красный' if vote_share > 0.5
else 'зелёный'}")
print(f"REFERENCE: {mean_p:.4f}; {vote_share:.4f}")
```

**Заметки:** Черновик ассистента по docs/bank_worksheet.md (14.10.2026). Проверьте решение сами и поставьте verified. Основа — ISLR (James et al.), гл. 8, упр. 5: голосование большинством и усреднение вероятностей дают разные классы (0,40 → «зелёный», 6 из 11 голосов → «красный»); числа свои. Лишние данные: глубина, время, accuracy на обучении, OOB. Эталон: data/refs/F10.py.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## Dev-задачи (только для отладки промпта, в оценку не входят)

### dev-A1

расчётная · ансамбли · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** В дискретном AdaBoost слабый классификатор на текущей итерации имеет взвешенную ошибку 0,2. Найдите его вес $\alpha = \frac{1}{2}\cdot\ln((1-\varepsilon)/\varepsilon)$ в итоговом ансамбле.
**EN:** In discrete AdaBoost, the weak classifier at the current iteration has a weighted error of 0.2. Find its weight $\alpha = \frac{1}{2}\cdot\ln((1-\varepsilon)/\varepsilon)$ in the final ensemble.

> **Эталон: 0,6931**, допуск ±1% (относительный)

**Расчёт эталона кодом (data/refs/dev-A1.py)**

```
# dev-A1: AdaBoost, взвешенная ошибка слабого классификатора 0.2. Вес alpha = 0.5*ln((1-e)/e).
import math

e = 0.2
print(f"REFERENCE: {0.5 * math.log((1 - e) / e):.4f}")
```

> **Заметки:** dev-задача для отладки промпта, в оценку не входит. $\alpha = \frac{1}{2}\cdot\ln((1-\varepsilon)/\varepsilon) = \frac{1}{2}\cdot\ln 4$; проверено кодом: data/refs/dev-A1.py.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

### dev-B1

верно / неверно · линейная регрессия · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** Верно или неверно утверждение: «Добавление ещё одного признака в линейную регрессию, обученную методом наименьших квадратов, не может уменьшить $R^2$ на обучающей выборке»? Обоснуйте ответ.
**EN:** Is the following statement true or false: "Adding one more feature to an ordinary least squares linear regression cannot decrease $R^2$ on the training set"? Justify your answer.

> **Эталон: верно**

**Рубрика**

**Ключевые аргументы:**

- МНК минимизирует сумму квадратов остатков; старое решение достижимо с нулевым весом нового признака, поэтому RSS не растёт и $R^2$ на обучении не падает
- на тесте $R^2$ может упасть; поэтому используют скорректированный $R^2$ или валидацию

**Типичные ошибки:**

- путать $R^2$ на обучении и на тесте
- ссылаться на скорректированный $R^2$ как на обычный

| Балл | Критерий |
|---|---|
| 2 | «верно» + довод про вложенность моделей (нулевой вес нового признака) |
| 1 | «верно», но без довода или с ошибкой |
| 0 | вердикт неверный или обоснования нет |

> **Заметки:** dev-задача для отладки промпта, в оценку не входит. Истинное (вложенные модели МНК).

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

### dev-C1

выбор метода · kNN · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** Нужен простой прототип для подбора аналогов деталей: 2 000 деталей, 5 числовых характеристик в разных единицах (мм, кг, МПа), 4 класса деталей. Инженер хочет видеть, на какие похожие детали опирается

прогноз класса. Какой метод выбрать и почему?

**EN:** A simple prototype is needed to find analogues of parts: 2,000 parts, 5 numeric characteristics in different units (mm, kg, MPa), 4 part classes. The engineer wants to see which similar parts the class prediction is based on. Which method would you choose and why?

> **Эталон:** kNN с масштабированием признаков

**Рубрика**

**Допустимые методы:**

- kNN-классификатор (со стандартизацией признаков)

**Обязательные аргументы (все нужны для 2 баллов):**

- прогноз объясняется списком ближайших похожих деталей — ровно то, что просит инженер
- признаки в разных единицах: обязательно масштабирование перед расстояниями
- k подбирается на кросс-валидации; данных немного, kNN работает быстро

**Типичные ошибки:**

- нет масштабирования
- метод, который не объясняет прогноз через похожие объекты, без оговорок

| Балл | Критерий |
|---|---|
| 2 | kNN + масштабирование + довод про объяснение через соседей |
| 1 | kNN без масштабирования или без довода про объяснение |
| 0 | другой метод без учёта требования или нет обоснования |

> **Заметки:** dev-задача для отладки промпта, в оценку не входит.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## dev-D1

код sklearn · деревья · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** Напиши код на Python (scikit-learn): на датасете load_iris подбери max_depth дерева решений на 5-кратной кросс-валидации и выведи accuracy на отложенной тестовой выборке. В тест отложи 30% данных, random_state=42. Код должен напечатать итоговое значение метрики.

**EN:** Write Python code (scikit-learn): on the load_iris dataset, tune max_depth of a decision tree with 5-fold cross-validation and print the accuracy on a held-out test set. Hold out 30% of the data for testing, random_state=42. The code must print the final metric value.

> **Эталон:** метрика эталонного решения: **0,9778**, допуск ±5% (относительный)

**Эталонное решение (data/d_reference/dev-D1.py)**

```
# dev-D1 (эталон): load_iris, дерево решений, подбор max_depth на 5-fold CV, accuracy на тесте.
from sklearn.datasets import load_iris
from sklearn.model_selection import GridSearchCV, StratifiedKFold, train_test_split
from sklearn.tree import DecisionTreeClassifier

X, y = load_iris(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, stratify=y, random_state=42)

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
search = GridSearchCV(DecisionTreeClassifier(random_state=42), {"max_depth": [1, 2, 3, 4, 5, None]}, cv=cv)
search.fit(X_train, y_train)

print("лучшая глубина:", search.best_params_["max_depth"])
print(f"METRIC: {search.score(X_test, y_test):.4f}")
```

> **Заметки:** dev-задача для отладки промпта, в оценку не входит. Тест 45 объектов: одна ошибка = 2,2%, отсюда допуск 0.05.

□ Решил(а) сам(а), эталон верен □ Есть замечание: _____

## dev-F1

ловушка · метрики качества · недостающие данные · источник: учебник · сложность 1 · статус эталона: verified

**Условие:** У бинарного классификатора на тестовой выборке precision = 0,8 и recall = 0,6. Сколько объектов в тестовой выборке?

**EN:** A binary classifier has precision = 0.8 and recall = 0.6 on the test set. How many objects are in the test set?

> **Эталон: нельзя определить** (правильный ответ — отказ дать число)

> **Заметки:** dev-задача для отладки промпта, в оценку не входит. Precision и recall не зависят от TN и масштаба выборки, размер выборки найти нельзя. Правильный ответ — «нельзя определить».

---

□ Решил(а) сам(а), эталон верен  □ Есть замечание: _____