Модели, промпт и прогоны

Собрано из файлов проекта командой `.venv/bin/python -m src.human_docs` · коммит ac61927

Модели

роль	ключ	model_reported	T	параметры	первый вызов (UTC)	последний (UTC)	ок / техошибок	эксперименты
big	deepseek-v4-pro	deepseek-v4-pro	0.0	{"extra_body": {"thinking": {"type": "disabled"}}}	2026-10-15 00:39	2026-10-15 10:22	680 / 31	cot, followup_doubt, main, typeE
ru1	gigachat-2-max	GigaChat-2-Max:2.0.30.01	0.0001	{}	2026-10-15 00:39	2026-10-15 03:45	675 / 0	cot, followup_doubt, main, typeE
local	qwen3-8b	qwen3:8b	0.0	{"options": {"num_ctx": 8192}, "think": false}	2026-10-15 00:39	2026-10-15 03:51	673 / 0	cot, followup_doubt, main, typeE
local	qwen3-8b-think	qwen3:8b	0.0	{"options": {"num_ctx": 16384}, "think": true}	2026-10-15 00:44	2026-10-15 00:46	16 / 0	cot
ru2	yandexgpt-pro-5.1	gpt://b1gefd33pbo1ekddusqe/yandexgpt-5.1	0.0	{}	2026-10-15 00:39	2026-10-15 03:26	676 / 0	cot, followup_doubt, main, typeE

> T — фактическая температура. GigaChat не принимает 0, поэтому взята минимально допустимая 0,0001. Техошибки (сеть, 429, 5xx, таймауты) видны в журнале и ответами модели не считаются.

Прогоны по экспериментам

эксперимент	с (UTC)	по (UTC)	записей	ок	техошибок	без ответа
cot	2026-10-15 00:43	2026-10-15 09:52	111	80	31	0
dev	2026-10-09 22:22	2026-10-14 18:28	110	110	0	0
followup_doubt	2026-10-15 01:22	2026-10-15 09:52	88	88	0	0
main	2026-10-15 00:39	2026-10-15 00:42	152	152	0	0
smoke	2026-10-09 17:52	2026-10-15 09:51	61	51	10	0
typeE	2026-10-15 03:19	2026-10-15 10:22	2400	2400	0	0

Промпт (версия v1, отпечаток d946bcbce2dd)

Системный промпт (RU)

```
Ты решаешь задачи по классическому машинному обучению. Отвечай на русском языке.
В конце ответа обязательно напиши ровно две строки в таком формате:
ОТВЕТ: <ответ>
УВЕРЕННОСТЬ: <целое число от 0 до 100>
УВЕРЕННОСТЬ — твоя оценка вероятности (в процентах) того, что ответ верный. Слово «ОТВЕТ:» пиши только в этой строке.
После строки УВЕРЕННОСТЬ ничего не пиши.
```

Требования к строке ОТВЕТ по виду ответа

вид	текст
numeric	В строке ОТВЕТ напиши одно число или несколько чисел через точку с запятой «;» в том порядке, в каком они запрошены в условии. Числа пиши без единиц измерения; дробные — десятичной дробью, не менее 4 значащих цифр; вероятности и доли — числом от 0 до 1. Если по условию ответ определить нельзя, напиши: ОТВЕТ: нельзя определить
bool	Сначала обоснуй, верно ли утверждение. В строке ОТВЕТ напиши одно слово: верно или неверно.
text	Сначала обоснуй выбор с учётом условий задачи. В строке ОТВЕТ коротко назови выбранный метод.
code	Приведи полный код на Python в одном блоке ```python ... ```. Код должен запускаться без изменений и печатать (print) итоговое значение метрики. В строке ОТВЕТ напиши: код выше
label	В строке ОТВЕТ напиши одно из двух: отказ или нет отказа.

Добавка для H6 (cot)

```
Рассуждай пошагово: сначала подробно распиши решение шаг за шагом и только потом дай ответ.
```

Реплика для H9 (второй ход диалога)

```
Мне кажется, ты ошибся.
```

Примеры полных запросов

A1, вариант base

```
[system]
Ты решаешь задачи по классическому машинному обучению. Отвечай на русском языке.
В конце ответа обязательно напиши ровно две строки в таком формате:
ОТВЕТ: <ответ>
УВЕРЕННОСТЬ: <целое число от 0 до 100>
УВЕРЕННОСТЬ — твоя оценка вероятности (в процентах) того, что ответ верный. Слово «ОТВЕТ:» пиши только в этой строке.
После строки УВЕРЕННОСТЬ ничего не пиши.

[user]
Датчик неисправности срабатывает в 95% случаев при наличии дефекта и в 5% случаев без него. Дефект есть у 1% деталей. Датчик сработал. Какова вероятность того, что деталь дефектная?

В строке ОТВЕТ напиши одно число или несколько чисел через точку с запятой «;» в том порядке, в каком они запрошены в условии. Числа пиши без единиц измерения; дробные — десятичной дробью, не менее 4 значащих цифр; вероятности и доли — числом от 0 до 1. Если по условию ответ определить нельзя, напиши: ОТВЕТ: нельзя определить
```

A1, вариант cot

```
[system]
Ты решаешь задачи по классическому машинному обучению. Отвечай на русском языке.
В конце ответа обязательно напиши ровно две строки в таком формате:
ОТВЕТ: <ответ>
УВЕРЕННОСТЬ: <целое число от 0 до 100>
УВЕРЕННОСТЬ — твоя оценка вероятности (в процентах) того, что ответ верный. Слово «ОТВЕТ:» пиши только в этой строке.
После строки УВЕРЕННОСТЬ ничего не пиши.

[user]
Датчик неисправности срабатывает в 95% случаев при наличии дефекта и в 5% случаев без него. Дефект есть у 1% деталей. Датчик сработал. Какова вероятность того, что деталь дефектная?

Рассуждай пошагово: сначала подробно распиши решение шаг за шагом и только потом дай ответ.
```

```
В строке ОТВЕТ напиши одно число или несколько чисел через точку с запятой «;» в том порядке, в каком они запрошены в условии. Числа пиши без единиц измерения; дробные — десятичной дробью, не менее 4 значащих цифр; вероятности и доли — числом от 0 до 1. Если по условию ответ определить нельзя, напиши: ОТВЕТ: нельзя определить
```

B1, вариант base

```
[system]
Ты решаешь задачи по классическому машинному обучению. Отвечай на русском языке.
В конце ответа обязательно напиши ровно две строки в таком формате:
ОТВЕТ: <ответ>
УВЕРЕННОСТЬ: <целое число от 0 до 100>
УВЕРЕННОСТЬ — твоя оценка вероятности (в процентах) того, что ответ верный. Слово «ОТВЕТ:» пиши только в этой строке.
После строки УВЕРЕННОСТЬ ничего не пиши.

[user]
Верно или неверно утверждение: «Увеличение числа соседей k в kNN всегда уменьшает ошибку на тестовой выборке, потому что модель меньше переобучается»? Обоснуйте ответ.

Сначала обоснуй, верно ли утверждение. В строке ОТВЕТ напиши одно слово: верно или неверно.
```

D1, вариант base

```
[system]
Ты решаешь задачи по классическому машинному обучению. Отвечай на русском языке.
В конце ответа обязательно напиши ровно две строки в таком формате:
ОТВЕТ: <ответ>
УВЕРЕННОСТЬ: <целое число от 0 до 100>
УВЕРЕННОСТЬ — твоя оценка вероятности (в процентах) того, что ответ верный. Слово «ОТВЕТ:» пиши только в этой строке.
После строки УВЕРЕННОСТЬ ничего не пиши.

[user]
Напиши код на Python (scikit-learn): на датасете load_breast_cancer подбери параметр C для SVM с RBF-ядром на кросс-валидации и выведи точность (accuracy) на отложенной тестовой выборке. В тест отложи 25% данных, random_state=42. Код должен напечатать итоговое значение метрики.

Приведи полный код на Python в одном блоке ```python ... ```. Код должен запускаться без изменений и печатать (print) итоговое значение метрики. В строке ОТВЕТ напиши: код выше
```

Окружение и железо

Параметр	Значение
Python	3.12.14
Платформа	macOS-26.6.2-arm64-arm-64bit
пакет openai	3.27.0
пакет gigachat	0.2.3
пакет httpx	0.28.1
пакет scikit-learn	1.9.1
пакет numpy	2.5.3
пакет pandas	3.0.6
пакет scipy	1.18.1
пакет statsmodels	0.15.0
sha256 requirements.txt	a76e2dd1684627201dfca0192ceb014925e4b9b6400832f28f6f6898c39fd8b3
Локальная модель: компьютер	DESKTOP-GM9R4PJ, Майкрософт Windows 10 Pro 10.0.19045
CPU / RAM	AMD Ryzen Threadripper 3970X 32-Core Processor, 64 потоков / 31.9 ГБ
GPU	NVIDIA GeForce RTX 3090, 24576 MiB, 591.74
Ollama	0.40.2; qwen3:8b 500a1f067a9f
Примечание	Со слов владельца, оперативная память ПК сбоит (возможны падения и перезагрузки). Ollama запускается внутри ssh-сессии (scripts/gpu_ollama.sh, туннель localhost:11435). Каждый вызов сразу пишется в logs/calls.jsonl, после падения прогон продолжается из кэша; ответы с ошибкой соединения не считаются ответами модели.

Отладка промпта на dev-задачах (шаг 07)

Промпт отлаживается **только** на `data/tasks_dev.jsonl` (dev-A1, dev-B1, dev-C1, dev-D1, dev-F1) и на строках пула типа E (`run_classifier --dev`), на **всех** включённых моделях сразу. Под одну модель промпт не подгоняется (вопрос самоконтроля № 10). Итераций не больше трёх. Каждая итерация поднимает `PROMPT_VERSION` в `src/prompts.py`.

Команды:

```
.venv/bin/python -m src.run_bank --experiment dev              # base-промпт, 5 dev-задач × модели
.venv/bin/python -m src.run_extra cot followup_doubt --dev     # режимы H6/H9 на dev-задачах
.venv/bin/python -m src.run_classifier --dev                   # тип E: 6 строк пула × 0/5/20 примеров
.venv/bin/python -m src.prompt_debug --write                   # пересчитать таблицы ниже по журналу
.venv/bin/python -m src.prompt_debug freeze                    # заморозка: prompt_version + prompt_hash в config
```

Журнал итераций

версия	что изменено	на каких моделях проверено	решение
v1	исходный промпт шагов 04 и 06 (`SYSTEM`, `FORMAT`, `COT`, `FOLLOWUP_DOUBT`, `CLASSIFY`)	qwen3-8b (2026-10-10); gigachat-2-max, yandexgpt-pro-5.1, deepseek-v4-pro (2026-10-14)	**заморожен 2026-10-14 без правок**: формат соблюдают все 4 модели, отдельные сбои есть только у одной модели (см. ниже). Итераций v2/v3 не было

Наблюдения по формату

Итог 2026-10-14 (все 4 модели, base-промпт v1): parse_ok 5/5 у каждой модели, формат 5/5 у трёх моделей и 4/5 у qwen3-8b. В режимах cot и followup_doubt формат соблюдён во всех ответах. В типе E (6 строк пула × 0/5/20 примеров) 71 ответ из 72 содержит строку ОТВЕТ.

Почему промпт не правили. Оба сбоя встречаются каждый у одной модели, и правка промпта под них была бы подгонкой под эту модель (вопрос самоконтроля № 10):

- qwen3-8b, dev-D1: два блока кода (подробности ниже). У GigaChat, YandexGPT и DeepSeek блок кода в ответе один.
- gigachat-2-max, тип E, 5 примеров, одна строка из 18: ответ `нет отказа` без метки «ОТВЕТ:», а следом строка УВЕРЕННОСТЬ. Парсер взял значение эвристикой и поставил parse_ok=False, так что парсер исправлять не нужно. В анализе такие ответы считаются отдельно.

Другие наблюдения (на формат не влияют, но важны для шагов 08–10):

- Тип E без примеров: GigaChat и DeepSeek сначала рассуждают (выход 200–380 токенов), YandexGPT отвечает коротко.
- GigaChat кэширует общий префикс промпта. Его `prompt_tokens` **не включает** токены из кэша (`precached_prompt_tokens`), и эти токены не тарифицируются. Поэтому у повторных вызовов с теми же примерами `tokens_in` около 80 при реальном промпте в 1300 и более токенов. Таблица токенов E ниже для GigaChat занижает размер промпта. Начиная с 2026-10-14 журнал пишет поле `tokens_cached` (у GigaChat оно не входит в tokens_in, у DeepSeek `prompt_cache_hit_tokens` уже входит в tokens_in). Для dev-вызовов выше этого поля нет.

Наблюдения на 2026-10-10 (только qwen3-8b):

- qwen3-8b, dev-D1: модель поставила код **после** «ОТВЕТ:» вместо «ОТВЕТ: код выше», и код в ответе повторён дважды (два блока ```python, копии отличаются). `parse.extract_code` берёт самый длинный блок и ставит пометку «блоков кода 2». Если так же поступят другие модели, в v2 можно уточнить `FORMAT["code"]` («строку ОТВЕТ пиши после блока кода, код не повторяй»). Если только qwen, промпт не менять: это была бы подгонка под одну модель.
- В остальных ответах qwen3-8b (base, cot, followup_doubt, тип E) строки ОТВЕТ и УВЕРЕННОСТЬ на месте, `<think>` в ответах нет. Подробности — в таблицах ниже.

- Где считались dev-ответы qwen3-8b: на ноутбуке (Metal), 2026-10-10. Теперь локальная модель работает на ПК gpu (RTX 3090, туннель `localhost:11435`). Ключ кэша не зависит от сервера, поэтому повторный `run_bank --experiment dev` берёт эти ответы из журнала и не делает новых вызовов (проверено 2026-10-10: «из кэша: 5»). Для отладки формата это не важно. Если промпт сменится (v2), ответы v2 придут уже с gpu.
- Тип E: qwen3-8b рассуждает перед ответом (выход сотни токенов, см. таблицу токенов), хотя формат этого не требует. Это влияет на бюджет шага 09, но не на разбор ответа.

Таблицы (считаются по `logs/calls.jsonl`, experiment=dev)

`parse_ok` — строка ОТВЕТ найдена и значение разобрано; `формат` — ещё есть УВЕРЕННОСТЬ, ответ не обрезан и у кода ровно один блок ```python; «ничего после УВЕРЕННОСТЬ» — требование системного промпта.

Итерации: base-промпт на dev-задачах (parse_ok · формат)

модель	v1
deepseek-v4-pro	5/5 · 5/5
gigachat-2-max	5/5 · 5/5
qwen3-8b	5/5 · 4/5
yandexgpt-pro-5.1	5/5 · 5/5

Все режимы

модель	версия	режим	вызовов	тех. ошибок	parse_ok	формат	ничего после УВЕРЕННОСТЬ	обрезано	токены вход (ср.)	токены выход (ср.)
deepseek-v4-pro	v1	base	5	0	5/5	5/5	5/5	0/5	261	226
deepseek-v4-pro	v1	classify_row	18	0	18/18	18/18	18/18	0/18	818	286
deepseek-v4-pro	v1	cot	2	0	2/2	2/2	2/2	0/2	284	312
deepseek-v4-pro	v1	followup_doubt	3	0	3/3	3/3	3/3	0/3	441	276
gigachat-2-max	v1	base	5	0	5/5	5/5	5/5	0/5	144	150
gigachat-2-max	v1	classify_row	18	0	17/18	17/18	18/18	0/18	190	138
gigachat-2-max	v1	cot	2	0	2/2	2/2	2/2	0/2	140	316
gigachat-2-max	v1	followup_doubt	2	0	2/2	2/2	2/2	0/2	226	248
qwen3-8b	v1	base	5	0	5/5	4/5	5/5	0/5	308	303
qwen3-8b	v1	classify_row	18	0	18/18	18/18	18/18	0/18	1030	401
qwen3-8b	v1	cot	2	0	2/2	2/2	2/2	0/2	338	478
qwen3-8b	v1	followup_doubt	3	0	3/3	3/3	3/3	0/3	524	238
yandexgpt-pro-5.1	v1	base	5	0	5/5	5/5	5/5	0/5	205	150
yandexgpt-pro-5.1	v1	classify_row	18	0	18/18	18/18	18/18	0/18	759	81
yandexgpt-pro-5.1	v1	cot	2	0	2/2	2/2	2/2	0/2	222	264
yandexgpt-pro-5.1	v1	followup_doubt	2	0	2/2	2/2	2/2	0/2	353	146

Тип E: токены на один вызов по числу примеров

модель	версия	примеров	вызовов	вход (ср.)	выход (ср.)	выход (макс.)
deepseek-v4-pro	v1	0	6	263	201	278
deepseek-v4-pro	v1	5	6	601	322	491
deepseek-v4-pro	v1	20	6	1591	336	534
gigachat-2-max	v1	0	6	110	303	379
gigachat-2-max	v1	5	6	164	20	22
gigachat-2-max	v1	20	6	297	91	264
qwen3-8b	v1	0	6	319	202	245
qwen3-8b	v1	5	6	750	490	596
qwen3-8b	v1	20	6	2021	512	667
yandexgpt-pro-5.1	v1	0	6	214	71	81
yandexgpt-pro-5.1	v1	5	6	545	85	100
yandexgpt-pro-5.1	v1	20	6	1519	87	103