Тип E: LLM как классификатор (AI4I 2020)

Собрано из файлов проекта командой `.venv/bin/python -m src.human_docs` · коммит ac61927

Файл	Что это	Кто создаёт
`tasks.jsonl`, `tasks_dev.jsonl`	банк задач и dev-задачи (схема в docstring `src/bank.py`)	шаг 03 + человек
`refs/`, `d_reference/`	эталоны задач, посчитанные кодом	шаг 03 + человек
`checklist_D.md`	чек-лист методологических ошибок для типа D	шаг 03
`ai4i2020.csv`	датасет AI4I 2020 для типа E (без изменений, все 14 колонок)	`src.typeE download`
`e_split.json`	разбиение типа E: тест, примеры few-shot, наборы для разброса, dev-строки	`src.typeE split`

AI4I 2020 (тип E)

- **Источник:** AI4I 2020 Predictive Maintenance Dataset, UCI Machine Learning Repository, id 601, https://archive.ics.uci.edu/dataset/601/ai4i+2020+predictive+maintenance+dataset (лицензия CC BY 4.0). Синтетический датасет, отражающий реальные данные предиктивного обслуживания; автор — S. Matzka, 2020.
- **Как получен:** `ucimlrepo.fetch_ucirepo(id=601)` (ucimlrepo 0.0.7), 2026-10-10. Запасной вариант в коде — zip с сайта UCI (`src/typeE.py::UCI_ZIP`). Колонки приведены к виду без единиц (`Air temperature`, а не `Air temperature [K]`), идентификатор строки назван `UDI`, как в исходном CSV (ucimlrepo называет его `UID`). Больше файл не меняется.
- **Повторить:** `.venv/bin/python -m src.typeE download` (перезапишет файл тем же содержимым).

Какие колонки используются

Признаки (6): `Type` (L/M/H — низкое, среднее, высокое качество изделия), `Air temperature` [K], `Process temperature` [K], `Rotational speed` [об/мин], `Torque` [Н·м], `Tool wear` [мин]. Цель: `Machine failure` (1 = отказ).

Удалены как утечки:

- `TWF, HDF, PWF, OSF, RNF` — виды отказа (износ инструмента, теплоотвод, мощность, перегрузка, случайный отказ). `Machine failure` по построению датасета равен 1, когда произошёл хотя бы один из них. Это разложение самой целевой переменной: в момент прогноза оно неизвестно, а модель с этими колонками угадывает цель почти без ошибок. Несколько строк не подчиняются правилу (случайный отказ RNF без `Machine failure` и наоборот) — посмотреть: `pd.crosstab(df["Machine failure"], df[["TWF","HDF","PWF","OSF","RNF"]].max(axis=1))`.
- `UDI`, `Product ID` — идентификаторы. `UDI` — номер строки, `Product ID` — тип изделия + серийный номер. Свойств станка они не несут, а номер строки может коррелировать с порядком генерации данных.

Удаление делает `src/typeE.py::features()`: файл хранится целиком, чтобы источник можно было сверить.

Разбиение (`e_split.json`)

Индексы — позиции строк в `ai4i2020.csv`, считая с 0 (`UDI` = индекс + 1). Параметры: `config/experiment.json` → `typeE`, seed — общий `seed`. Код: `src/typeE.py::make_split`, инварианты проверяет `check_split` (и тесты `tests/test_typeE.py`).

- **Тест** (`test`): 200 строк. По умолчанию **обогащён**: 40 отказов + 160 без отказа (`test_mode: enriched`). При естественной доле отказов (около 3,4%) в тесте было бы ~7 отказов, и F1 редкого класса считался бы

по семи строкам. Цена: доля отказов в тесте (20%) не равна реальной, поэтому accuracy на тесте нельзя переносить на реальные данные. Константа «всегда нет отказа» при естественной доле считается отдельно (`results/typeE_classical.csv`, `eval_set=full`). Альтернатива — `test_mode: natural` (решает человек). Строки теста перемешаны (seed): пробный прогон `--limit 20` берёт начало списка, где есть оба класса.

- **Пул** — все строки вне теста. Примеры few-shot и dev-строки берутся только из пула.
- **Few-shot** (`shots`): стратифицированно и вложенно. Набор 20 = 5 отказов + 15 без отказа, набор 5 = 2 + 3, это часть набора 20. Порядок примеров в промпте случайный (seed), у набора 5 тот же относительный порядок. Почему не случайно: в пуле около 3,4% отказов, и 5 или 20 случайных примеров часто оказались бы одного класса (вопрос самоконтроля № 8). Тогда ни LLM, ни LogReg/NB не увидели бы ни одного отказа, и сравнение потеряло бы смысл. Вложенность ($5 \subset 20$) нужна, чтобы разница $5 \rightarrow 20$ была эффектом числа примеров, а не другого набора. Доля отказов в примерах (40% и 25%) выше реальной — это тоже искажает априорную долю класса, отметить в ограничениях.
- **Наборы для разброса** (`resamples`): ещё 20 пар вложенных наборов того же состава (отдельный seed + 1). На них обучаются только LogReg и NB (без API), чтобы показать, насколько качество зависит от выбора примеров.
- **Dev-строки** (`dev_rows`): 6 строк пула (3 отказа + 3 без отказа), не из теста и не из примеров. Нужны для отладки промпта типа E на реальных моделях (шаг 07, `experiment=dev`), чтобы не трогать тест.

Разбиение (data/e_split.json)

Параметр	Значение
dataset	AI4I 2020 Predictive Maintenance (UCI id 601)
seed	42
test_mode	enriched
n_rows	10000
n_failures_total	339
natural_failure_rate	0.0339
n_test	200
n_test_failures	40
pool_size	9800
pool_failures	299
few-shot набор «20»	20 примеров
few-shot набор «5»	5 примеров

Пример запроса к модели (5 примеров, первая тестовая строка)

```
[system]
Ты решаешь задачи по классическому машинному обучению. Отвечай на русском языке.
В конце ответа обязательно напиши ровно две строки в таком формате:
ОТВЕТ: <ответ>
УВЕРЕННОСТЬ: <целое число от 0 до 100>
УВЕРЕННОСТЬ — твоя оценка вероятности (в процентах) того, что ответ верный. Слово «ОТВЕТ:» пиши только в этой строке. После строки УВЕРЕННОСТЬ ничего не пиши.

[user]
По показаниям датчиков станка определи, произойдёт ли отказ оборудования. Тип изделия L, M или H означает низкое, среднее или высокое качество изделия.

Примеры с известным исходом:
1. Тип изделия: L. Температура воздуха 297,3 K, температура процесса 308,1 K, скорость вращения 1 615 об/мин, крутящий момент 35,4 Н·м, износ инструмента 217 мин. Исход: отказ.
2. Тип изделия: L. Температура воздуха 301,7 K, температура процесса 311,2 K, скорость вращения 1 517 об/мин, крутящий момент 42,4 Н·м, износ инструмента 113 мин. Исход: нет отказа.
3. Тип изделия: L. Температура воздуха 302,4 K, температура процесса 311,9 K, скорость вращения 1 452 об/мин, крутящий момент 43,1 Н·м, износ инструмента 137 мин. Исход: нет отказа.
4. Тип изделия: H. Температура воздуха 298,2 K, температура процесса 307,9 K, скорость вращения 1 462 об/мин, крутящий момент 45,5 Н·м, износ инструмента 171 мин. Исход: нет отказа.
5. Тип изделия: M. Температура воздуха 297,4 K, температура процесса 308,8 K, скорость вращения 1 325 об/мин, крутящий момент 62,4 Н·м, износ инструмента 204 мин. Исход: отказ.

Определи исход для станка:
Тип изделия: H. Температура воздуха 301,5 K, температура процесса 310,8 K, скорость вращения 1 591 об/мин, крутящий момент 29,6 Н·м, износ инструмента 33 мин.

В строке ОТВЕТ напиши одно из двух: отказ или нет отказа.
```

Метрики (results/typeE_metrics.csv)

> Только числа из файла, без выводов. «Набор примеров»: prompt — примеры в промпте LLM; fixed — LogReg / NB / Dummy обучены на тех же 5 или 20 примерах; resample — среднее по 20 случайным стратифицированным наборам (sd — разброс); none — без примеров. Строка constant — всегда «нет отказа» на всём датасете (естественная доля отказов).

источник	модель	примеров	набор примеров	строк	доля разобранных	F1 «отказ»	balanced acc.	accuracy	F1 sd	BA sd	токенов на входе (ср.)	задержка, с (ср.)
llm	deepseek-v4-pro	0	none	200	1	0,315	0,566	0,695			263	4,656
llm	deepseek-v4-pro	5	prompt	200	1	0,457	0,666	0,75			601	5,441
llm	deepseek-v4-pro	20	prompt	200	1	0,566	0,762	0,77			1591	5,512
llm	gigachat-2-max	0	none	200	0,995	0,283	0,509	0,545			80,17	5,11
llm	gigachat-2-max	5	prompt	200	1	0,556	0,734	0,8			86,28	0,93
llm	gigachat-2-max	20	prompt	200	1	0,632	0,762	0,86			119,675	1,473
llm	qwen3-8b	0	none	200	1	0,356	0,55	0,295			318,43	1,641
llm	qwen3-8b	5	prompt	200	1	0,396	0,622	0,665			749,43	3,296
llm	qwen3-8b	20	prompt	200	1	0,424	0,637	0,81			2020,43	4,609
llm	yandexgpt-pro-5.1	0	none	200	1	0,333	0,528	0,38			213,43	1,293
llm	yandexgpt-pro-5.1	5	prompt	200	1	0,433	0,641	0,83			544,43	1,304
llm	yandexgpt-pro-5.1	20	prompt	200	1	0,476	0,662	0,835			1518,43	1,281
classical	Dummy(most_frequent)	5	fixed	200	1	0	0,5	0,8				
classical	Dummy(most_frequent)	20	fixed	200	1	0	0,5	0,8				
classical	GaussianNB	5	fixed	200	1	0,28	0,525	0,615				
classical	GaussianNB	20	fixed	200	1	0,406	0,631	0,605				
classical	LogisticRegression	5	fixed	200	1	0,281	0,572	0,795				
classical	LogisticRegression	20	fixed	200	1	0,192	0,541	0,79				
classical	GaussianNB	5	resample	200	1	0,207	0,539	0,719	0,193	0,091		
classical	GaussianNB	20	resample	200	1	0,488	0,68	0,7	0,113	0,085		
classical	LogisticRegression	5	resample	200	1	0,448	0,665	0,736	0,143	0,088		
classical	LogisticRegression	20	resample	200	1	0,474	0,667	0,834	0,168	0,091		
classical	constant(нет отказа)		none	10000	1	0	0,5	0,966				