Тарифы для расчёта стоимости

Собрано из файлов проекта командой `.venv/bin/python -m src.human_docs` · коммит ac61927

Поле	Значение
verified_by_human	False
date_checked	2026-10-10
checked_by	агент, шаг 10 (WebSearch/WebFetch официальных страниц)
unit	RUB за 1 млн токенов
usd_rub	{'rate': 84.9048, 'date': '2026-10-10', 'source_url': 'https://www.cbr.ru/scripts/XML_daily.asp?date_req=10/10/2026', 'note': 'официальный курс ЦБ РФ, установлен на 10.10.2026 (на 09.10.2026 было 85,4173)'}

> Сверьте цены с официальными страницами (source_url), впишите дату и поставьте `"verified_by_human": true` в `config/pricing.json`.

модель	₽ / 1 млн вход	₽ / 1 млн выход	НДС	исходная цена	источник	дата	примечание
gigachat-2-max	650	650	True	{"currency": "RUB", "price": "пакет 3 000 000 токенов GigaChat 2 Max = 1 950 ₽ с НДС (физлица); юрлица pay-as-you-go 0,65 ₽ за 1000 токенов с НДС, синхронный режим"}	https://developers.sber.ru/docs/ru/gigachat/tariffs/individual-tariffs	2026-10-10	Для физлиц (scope GIGACHAT_API_PERS) оплаты за токен нет: Freemium (25 млн токенов Max на 12 мес., один поток) или пакеты. Взята цена пакета на 1 млн = цене юрлиц за токен (вход и выход не различаются). С 01.09.2026 новые клиенты платят через cloud.ru: GigaChat-2-Max 569,3374 ₽ за 1 млн вход и выход с НДС 22% (https://cdn.cloud.ru/docs/legal/tariffs/evolution/future-version/foundation-models.pdf, «версия 260915»). Какую цену брать в отчёт — решает человек.
gigachat-2-lite	65	65	True	{"currency": "RUB", "price": "пакет 20 000 000 токенов GigaChat 2 Lite = 1 300 ₽ с НДС; юрлица 0,065 ₽ за 1000 токенов"}	https://developers.sber.ru/docs/ru/gigachat/tariffs/individual-tariffs	2026-10-10	Модель выключена в config/models.json (альтернатива).
gigachat-3-ultra			True	{"currency": "RUB", "price": "на developers.sber.ru платного тарифа нет, только Freemium (50 млн токенов для физлиц)"}	https://developers.sber.ru/docs/ru/gigachat/tariffs/individual-tariffs	2026-10-10	Модель выключена. На cloud.ru «GigaChat Ultra» 96,2214 ₽ вход / 288,6032 ₽ выход за 1 млн с НДС, но соответствие API-модели GigaChat-3-Ultra не подтверждено — если включите модель, подтвердите цену.
yandexgpt-pro-5.1	800	800	True	{"currency": "RUB", "price": "YandexGPT Pro 5.1, синхронный режим: 0,8 ₽ за 1000 входящих и 0,8 ₽ за 1000 исходящих токенов, вкл. НДС"}	https://aistudio.yandex.ru/docs/ru/ai-studio/pricing	2026-10-10	Асинхронный режим 0,41 ₽ за 1000 (не используется). Страница отдаёт капчу скриптам — числа прочитаны через WebFetch дважды, проверьте в браузере.
aliceai-llm	500	1200	True	{"currency": "RUB", "price": "Alice AI LLM, синхронный: 0,5 ₽ за 1000 входящих, 1,2 ₽ за 1000 исходящих, вкл. НДС"}	https://aistudio.yandex.ru/docs/ru/ai-studio/pricing	2026-10-10	Модель выключена (альтернатива).

deepseek-v4-pro	112,07	336,22	False	{"currency": "USD", "unit": "за 1 млн токенов", "in_cache_miss": 1.32, "in_cache_hit": 0.044, "out": 3.96, "off_peak": {"in_cache_miss": 0.66, "in_cache_hit": 0.022, "out": 1.98}}	https://api-docs.deepseek.com/quick_start/pricing	2026-10-10	Взята цена в часы пик и без кэша (верхняя оценка): время вызова может попасть в любой период; с 14.10.2026 журнал хранит tokens_cached (prompt_cache_hit_tokens, у DeepSeek они уже входят в tokens_in), так что при желании человек может посчитать и цену с кэшем. Вне пика цена вдвое ниже (пик: 01:00–04:00 и 06:00–10:00 UTC, пн–пт, кроме праздников КНР). Цена в USD без НДС.
deepseek-flash	25,47	101,89	False	{"currency": "USD", "unit": "за 1 млн токенов", "in_cache_miss": 0.3, "in_cache_hit": 0.006, "out": 1.2, "off_peak": {"in_cache_miss": 0.15, "in_cache_hit": 0.003, "out": 0.6}}	https://api-docs.deepseek.com/quick_start/pricing	2026-10-10	Модель выключена (альтернатива). Те же правила пика, что у deepseek-v4-pro.
qwen3-8b	0	0		{"currency": null, "price": "локальная модель (Ollama на ПК gpu), оплаты за токены нет"}		2026-10-10	Вместо цены — время и память: latency_s в журнале, память модели local_vram_mb / local_model_size_mb из журнала (/api/ps Ollama), железо — results/run_manifest.json → ollama_server. Электроэнергию не считаем.
qwen3-8b-think	0	0		{"currency": null, "price": "локальная модель, оплаты за токены нет"}		2026-10-10	Как qwen3-8b (только для H6).