Что осталось сделать человеку

Собрано из файлов проекта командой `.venv/bin/python -m src.human_docs` · коммит ac61927

G1 пройден 15.10.2026: гипотезы H1, H6, H9 закоммичены до прогонов (67d7108), банк из 38 задач подтверждён, промпт v1 заморожен, все прогоны на 4 реальных моделях получены полностью (DeepSeek дозапрошен в тот же день, ошибок без ответа нет). Анализ и каркас отчёта проверены на этих данных без ручных оценок, воспроизводимость в чистом окружении подтверждена (`docs/reproducibility.md`). Осталось то, что по правилам преподавателя (`CLAUDE.md`) делает только человек: **G2** (слепая проверка, парсер, тарифы), затем **G3** (выводы, отчёт, защита).

Как устроено: агентский флоу (`python3 flow/flow.py run`) сам перезапускает отложенные шаги 07–12, когда вы проходите гейт. Где работа сейчас — `python3 flow/flow.py status`. Агенты дописывают новые пункты в формате `(шаг NN)` в раздел своего гейта или в конец файла.

Формат пункта: **что сделать** — где лежит заготовка и как делать — *проверка: как понять, что сделано*.

С чего начать

Порядок важен: гипотезы выбирались до банка, коммит гипотез — до любых оценочных прогонов (выполнено). Дальше: G2 → повторный запуск флоу → G3.

#	Блок	Раздел	Готово, если	Статус
1	Ключи API, `.env`, smoke-тест 4 моделей	G1	`.venv/bin/python -m src.smoke_test` → код 0	✅ сделано
2	Выбрать 3 гипотезы, записать прогноз, **коммит**	G1	`src.checks hypcommit` печатает хэш	✅ сделано (67d7108)
3	Банк: 20 своих задач, проверка черновиков агента, переводы, рубрики	G1	`src.bank validate --final` → код 0	✅ сделано
4	Прогоны (флоу, шаги 07–10)	G1	`src.manifest` → «без ответа 0»	✅ сделано 15.10
5	**Найти второго проверяющего**; слепая проверка B/C/D двумя людьми (3–5 ч на каждого), выборка парсера, тарифы (≈1 ч)	G2	`.venv/bin/python -m src.checks g2` → код 0	⏳ **сейчас**
6	Запустить флоу ещё раз: анализ, кандидаты ошибок, отчёт (10 мин + ~15 мин машинного)	G3.1	шаги 11–12 done	ждёт G2
7	Выводы по гипотезам, 5 ошибок, ограничения, рекомендации, вопросы самоконтроля, доклад (8–12 ч)	G3.2–G3.4	`.venv/bin/python -m src.build_report check` → код 0	ждёт G2
8	Воспроизводимость, сдача, подготовка к защите (2–3 ч)	G3.5	`scripts/check_reproducibility.sh` → «Итог: совпадает»	ждёт G2

G1 — перед прогонами: пройден 15.10.2026

Все пункты закрыты (проверка `.venv/bin/python -m src.checks g1` прошла 15.10 03:38). Подробности прежних пунктов — `git show 43538a6:HUMAN_TODO.md`.

- [x] (шаг 01, 02) **Ключи, `.env`, TLS GigaChat, smoke-тест 4 моделей** — 14.10: все ключи в `.env`, бандл `certs/ca_bundle_with_russian_root.pem`, smoke 4/4 ok.
- [x] (шаг 03) **Гипотезы и прогноз** — H1, H6, H9 закоммичены 14.10 22:00 +03 (67d7108), все оценочные вызовы позже; `qwen3-8b-think` добавлен в `cot.extra_models` для H6. H2/H4/H7/H8 не выбраны, их требования к банку не нужны.
- [x] (шаг 03, 13) **Банк задач** — 38 задач, все `verified` (коммит cc31f37 «Банк задач: эталоны подтверждены»), dev-задачи тоже; `.venv/bin/python -m src.bank validate --final` → код 0.
- [x] (шаг 02, 04–07) **Решения агента по моделям, промпту, автопроверке, типу E и запуску кода D** приняты по умолчанию: прогоны выполнены с ними (модели GigaChat-2-Max, yandexgpt-5.1, deepseek-v4-pro, qwen3:8b; промпт v1 `d946bcbce2dd`; тест E обогащённый 200/40; код D без песочницы). Менять их теперь нельзя без новых прогонов. Если вы с чем-то не согласны, опишите это в ограничениях (G3.2). Правила подсчёта — пункт G3.1.
- [x] (шаг 07–10) **Прогоны** — main 152, cot 80, followup 88, E 2400, код D 24, техошибок без ответа 0 (`.venv/bin/python -m src.manifest`); `results/typeE_metrics.csv` 12 строк LLM `complete=True`. Ответы DeepSeek для H6, H9 и E получены на 7–9 ч позже, чем у остальных моделей (API не отвечал): отчёт показывает это в 2.1 («Когда получены ответы») и в справке к ограничениям.

G2 — ручная проверка (после шагов 07–10) ← сейчас

- [ ] (шаг 03, 12) **Найти второго проверяющего** для слепой проверки B (обоснование), C и D: проверяют два человека, не LLM (вопрос самоконтроля 3) — *проверка: имя второго проверяющего записано в `flow/HUMAN_NOTES.md` и в блоке `methods_extra` отчёта.*
- [ ] (шаг 10) **Слепые листы готовы, проверку можно начинать** — 15.10 собраны по реальному основному прогону: `grading/sheet_r1.csv`, `sheet_r2.csv` по 80 строк (B 32, C 24, D 24; корректность метрики D вручную нужна в 6 строках, в остальных «—» = авто-верно). Дозапрос DeepSeek (cot, followup, E) листы не изменил: в них только `main`. `grading/parser_spotcheck.csv` пересобран после дозапроса (15.10) и больше не пересобирается, если в нём есть ваши отметки — *проверка: `.venv/bin/python -m src.blind` печатает те же 80 строк, код 0.*
- [ ] (шаг 10) **Решить правило для числового ответа с несколькими числами** — qwen3-8b в main ответил на A2 «ОТВЕТ: 0.32;0.1987;0.1213» и на F2 «ОТВЕТ: 0.42;0.2852;0.1348» (последнее число близко к эталону). Парсер по правилу шага 04 берёт первое число → «неверно»; это пара P2 (гипотеза H1). Варианты: оставить (нарушение формата = ошибка), брать последнее число или считать неразобранным. После пересборки 15.10 A2 и F2 в выборку парсера не попали: смотрите их в `results/main_ru.jsonl` (`task_id`, `model_key`, `response_text`). Решение записать в `flow/HUMAN_NOTES.md`; если правило меняется — правка `src/parse.py` + тест, затем `.venv/bin/python -m src.autograde` (новых вызовов не нужно) — *проверка: решение записано в HUMAN_NOTES, `results/graded_auto.jsonl` пересобран после правки.*
- [ ] (шаг 10) **Оба проверяющих читают `grading/INSTRUCTIONS.md` и подтверждают правила** до начала оценки. Решения агента: нет кода в ответе D → весь чек-лист «н/п» (pass@1 = 0, из доли методологических ошибок исключается); корректность метрики D ставят люди везде, кроме авто-«верно»; в листы идут B, C, D из `main` и `paraphrase` (и EN при H4), но не из cot/selfconsistency/followup. Поправить можно `grading/INSTRUCTIONS.md` или `autograde.BLIND_EXPERIMENTS` до начала — *проверка: оба прочитали инструкцию до первой оценки.*
- [ ] **Слепая проверка двумя людьми независимо** — проверяющий 1 заполняет `grading/sheet_r1.csv`, проверяющий 2 — `grading/sheet_r2.csv`. Не обсуждать оценки, не

открывать `grading/key_DO_NOT_OPEN.csv`, клетки «—» не трогать, сохранять как CSV UTF-8 с тем же именем — *проверка: `.venv/bin/python -m src.checks g2` не пишет «не заполнено клеток» и «недопустимые значения».*

- [ ] (шаг 04, 10) **Выборочная проверка парсера** — `grading/parser_spotcheck.csv`: в `human_agrees` «да»/«нет» (согласны ли с `parsed_value` и `auto_correct`), в `comment` — что не так. До 10 строк — «подозрительные» (`selection`), остальные случайные; полный ответ в `response_text` — *проверка: `src.checks g2` показывает ✓ для выборки парсера.*
- [ ] (шаг 10) **Сверить тарифы** `config/pricing.json` с официальными страницами (`source_url`, курс ЦБ `usd_rub`) и выбрать цену для отчёта: GigaChat-2-Max 650 ₽/1 млн (новые клиенты с 01.09.2026 через cloud.ru — 569,34 ₽, см. `note`); DeepSeek — цена пика без кэша (верхняя оценка, вне пика вдвое ниже; USD без НДС, ₽ с НДС); GigaChat: токены из кэша (`precached_prompt_tokens`, в журнале поле `tokens_cached`) по документации не тарифицируются и в `tokens_in` не входят — подтвердить; YandexGPT — сверить в браузере (скриптам страница отдаёт капчу). Поставить `"verified_by_human": true`, обновить `date_checked` — *проверка: `src.checks g2` показывает ✓ для тарифов.*
- [ ] (шаг 11) **Сразу после листов посмотреть каппу** — `.venv/bin/python -c "from src import analysis as an; print(an.kappa_table(an.load_manual(an.paths(False)['grading'])))"`. Если у B, C или D к < 0,6: уточнить рубрику (`data/tasks.jsonl`, `data/checklist_D.md`), сохранить копию листов и вслепую переоценить оба листа — *проверка: `below_min` везде False.*
- [ ] (шаг 10) **Закоммитить листы** — `.venv/bin/python -m src.checks g2` → код 0, затем `git add grading/ config/pricing.json && git commit` — *проверка: команда печатает «Все условия G2 выполнены».*

G3 — финал (после шагов 11–12)

G3.1. Анализ и каркас отчёта

- [ ] (шаг 11, 12) **Запустить флоу ещё раз** (`python3 flow/flow.py run`) или вручную `scripts/run_analysis.sh` → `analysis.ipynb` с выходами, `report/figures/`, `results/summary_metrics.json`, `report/error_candidates.md`, `report/report.md`; затем коммит — *проверка: `results/summary_metrics.json` содержит `"demo": false`, в разделах 2–3 `report/report.md` нет «нет данных» (кроме невыбранных режимов); в отчёте, 3.1 «Полнота прогонов», нет пометок «**неполный**» — иначе в ограничениях отчёта указать, у какой модели и на скольких ответах неполные данные (после дозапроса 15.10 все прогоны полные; справка над блоком `limitations` сама перечисляет неполные прогоны и модели, ответившие позже остальных).*

- [ ] (шаг 11) **Подтвердить правила подсчёта** (`src/analysis.py`, константы в начале файла; поменять можно до выводов): C «верно» при балле ≥ 1 (`C_CORRECT_MIN_SCORE`); итог C и D — среднее двух проверяющих (0; 0,5; 1), 0,5 в точности идёт как половина; в Макнемаре и других парных сравнениях задачи с 0,5 не участвуют; точность банка — A, B (вердикт), C, D, F основного прогона RU, E отдельно, балл 0–2 B/C отдельной таблицей; отказ в `accuracy` — ошибка (кроме задач с недостающими данными), в `accuracy_answered` исключён (вопрос 9); H10 — A/B/F, 5 корзин равной ширины; H7 — «разброс» = больше одного ответа или часть не разобрана; H13 — локальная модель не участвует в выборе «лучшей по ₽»; H12 — неответ = ошибка; доля ответов ≈ P(+|D) для H2 не считается; H6 — отношение «токены всего» cot/main у GigaChat считается по полному входу (`tokens_in` + `tokens_cached` из журнала), а ₽ — по `tokens_in` (кэш GigaChat не тарифицируется); в таблице цены `tokens_in_full_mean` — тот же полный вход — *проверка: правила устраивают или описаны в блоке `methods_extra` отчёта.*

- ☐ (шаг 13) **Описать в методике различия параметров моделей** (блок `methods_extra`; задание требует «одинаковые промпты и параметры»): `max_tokens` не задан — действуют умолчания провайдеров (обрезанные ответы видны в `results/run_manifest.json` → `finish_reason_length`); GigaChat T = 0,0001 (API не принимает 0); у DeepSeek и qwen3 режим рассуждений выключен. Там же: на тепловой карте «модель × тип» нет типа E (для E основные метрики F1 и balanced accuracy, они в разделе 3.6); доли H3, H7 (разброс), H8, H9 — с точным интервалом Клоппера–Пирсона, остальные точности — бутстреп — *проверка: в отчёте эти пункты описаны вашими словами.*

- ☐ (шаг 11, 12) **Невыбранные гипотезы**: блоки с данными ноутбук считает, отчёт показывает в 3.9 «Прочие гипотезы (разведочный анализ)». Убрать — только удалив блок в `analysis.ipynb` и перезапустив `scripts/run_analysis.sh` (числа в `report/report.md` руками не правятся) — *проверка: в отчёте только те гипотезы, которые вы хотите показать.*

- ☐ (шаг 13) **Решить, считать ли все метрики надёжности из таблицы задания** (стр. 6–7: устойчивость к перефразированию, flip rate, разброс между 5 повторами). Посчитан только flip rate (H9, `followup_doubt`). Варианты: (а) написать в методике или ограничениях, что остальные метрики не считались; (б) дозапустить `.venv/bin/python -m src.run_extra paraphrase selfconsistency` (≈ +570 вызовов на 4 модели; перефразировки A1–A8, B1–B4 — черновики агента, их сначала проверить), затем `src.autograde`, `src.blind` (листы дополнятся строками `paraphrase`) и повторить анализ. Это новые прогоны, а не перезапрос: гипотезы уже закоммичены, такие гипотезы попадут в 3.9 «разведочный анализ» — *проверка: решение записано в `flow/HUMAN_NOTES.md`.*

G3.2. Выводы (пишет только человек)

- ☐ **Выводы по выбранным гипотезам** — ячейки «**Вывод (заполняет человек):**» в `analysis.ipynb` и блоки `verdict.H…` в `report/report.md`: подтвердилась / опровергнута / данных недостаточно, сравнение с прогнозом из коммита, опора на числа раздела 3 — *проверка: после «Вывод (заполняет человек):» у выбранных гипотез нет «…».*
- ☐ (шаг 12) **Текст отчёта** — только между строками `<div class="human">✍ <b>Заполняет человек: </b> id — …</div>` и `` в `report/report.md` (сохраняется при пересборке, всё остальное перезаписывается): `authors`, `intro`, `methods_extra` (необязательно), `verdict.H…`, `error.1`–`error.5`, `limitations`, `recommendations`, `conclusion` — *проверка: `.venv/bin/python -m src.build_report check` → «не заполнены: нет», код 0.*
- ☐ (шаг 12) **Разбор 5 ошибок с цитатами** (блоки `error.1`–`error.5`): в каком месте рассуждения модель сбилась и почему. Кандидаты с точными цитатами и `call_id` — `report/error_candidates.md`; можно взять другие, цитату брать из `logs/calls.jsonl` по `call_id`. Для SVM-задачи A4 посмотреть, заметила ли модель, что точка (1; 0) лежит на границе зазора (вопрос 12) — *проверка: у каждой ошибки указаны задача, модель, `call_id` и цитата.*
- ☐ (шаг 06, 12) **Ограничения, не меньше трёх** (блок `limitations`). Над блоком — справка с фактами из файлов (тест E, железо и сбоящая память ПК `gpu`, тарифы, техошибки, к, модели, ответившие на 7–9 ч позже остальных, — DeepSeek в H6, H9 и E). Кандидаты по E (формулировать вам): тест обогащён отказами (20% вместо ~3,4%), доля отказов в few-shot 40% и 25%, AI4I публичный и синтетический — *проверка: в разделе 5 отчёта ваши формулировки.*
- ☐ **Таблица рекомендаций** «тип задачи → можно доверять / проверять выборочно / не доверять» (блок `recommendations`, заготовка по типам A–F уже стоит) — *проверка: `src.build_report check` не называет `recommendations`.*

G3.3. Вопросы самоконтроля и доклад

- [ ] (шаг 12) **Ответить на 12 вопросов самоконтроля** — `report/selfcheck_questions.md` (под каждым вопросом указано, где лежат относящиеся к нему числа) — *проверка: под каждым «**Ответ (пишет человек):**» есть текст.*
- [ ] (шаг 12) **Доклад на 5 минут** — план `report/slides_outline.md` (что на каком слайде, места под выводы) — *проверка: доклад укладывается в 5 минут на прогоне вслух.*

G3.4. Формат сдачи

- [ ] (шаг 12) **Решить формат отчёта** (PDF / docx / markdown). `report/report.md` ссылается на `figures/*.png` относительными путями; конвертировать готовый markdown (например, pandoc) после заполнения всех блоков — *проверка: в сданном файле видны все рисунки и таблицы.*

G3.5. Воспроизводимость и защита

- [ ] (шаг 12) **Проверить воспроизводимость на финальных данных** — 15.10 агент дважды проверил на реальных прогонах без ручных оценок, последний раз — на полных данных (совпало, `docs/reproducibility.md`); после G2 это сделает повторный запуск флоу (шаг 12), вручную — `scripts/check_reproducibility.sh` (≈2–5 мин: копия проекта, новое `.venv` из `requirements.txt`, Restart & Run All, сравнение `results/summary_metrics.json`) и строка в «Журнал проверок» `docs/reproducibility.md` — *проверка: «Итог: совпадает», код 0, в журнале проверок строка «реальные данные, финально».*
- [ ] **Подготовка к защите**: самим выполнить Restart & Run All `analysis.ipynb` и разобраться в каждой ячейке и в коде `src/` (попросят объяснить любую строку). Карта «требование задания → код» — `docs/requirements_traceability.md` — *проверка: можете объяснить каждую строку ячеек раздела, который выберет преподаватель.*

Можно делать в любой момент

- [ ] (шаг 05, 11, 12) **Посмотреть весь конвейер на mock** — `scripts/run_experiments.sh --demo && scripts/run_analysis.sh --demo` (вызовов API нет, всё в `demo/`, числа — не результаты): `demo/analysis_demo.ipynb`, `demo/report/figures/`, `demo/report/report.md`, `demo/report/error_candidates.md`. Реальный каркас — `report/report.md` (методика: промпт, окружение, железо; разделы результатов — «нет данных» до `scripts/run_analysis.sh` после G2) — *проверка: скрипты печатают «=== Готово ===» и «Готово», на рисунках надпись DEMO, в демо-отчёте вверху пометка «ДЕМО».*

Добавлено агентами (без привязки к гейту)

- [ ] (шаг 12) **Решить, показывать ли идентификатор каталога Yandex Cloud** — `report/report.md` заменяет его на `<YANDEX_FOLDER_ID>` в URI модели (`gpt://…/yandexgpt-5.1`), но в закоммиченных `logs/calls.jsonl` и `results/*.jsonl`, `run_manifest.json` он есть как вернул API (это не ключ: без `YANDEX_API_KEY` доступа не даёт; журнал по правилам не переписывается). Если репозиторий будет публичным — решить, допустимо ли это — *проверка: решение записано в `flow/HUMAN_NOTES.md`.*
- [ ] (шаг 08) **Сверить списание DeepSeek за 15.10 с журналом** — запросы с `TimeoutError: нет полного ответа` (и `APITimeoutError` / `Connection error` у deepseek-v4-pro в `logs/calls.jsonl` 15.10) ответа не получили; если DeepSeek всё же их выполнил и списал деньги, в журнале этих токенов нет. Сравнить расход на https://platform.deepseek.com/usage за 15.10 с суммой

tokens_in/out успешных вызовов deepseek-v4-pro за эту дату; расхождение упомянуть в разделе о стоимости (H6, H13) — *проверка: сравнение записано в `flow/HUMAN_NOTES.md`.*