# ЛР: LLM и AutoML — задания для студентов

Sep 27, 2026 · @Maria Skvortsova

## Общие положения

Курс «Методы машинного обучения», 3 курс бакалавриата. Две лабораторные работы исследовательского типа: у вас нет «правильного ответа», который нужно получить. Вы формулируете гипотезу, ставите эксперимент, измеряете и честно пишете, подтвердилась она или нет. Опровергнутая гипотеза с аккуратным экспериментом оценивается так же высоко, как подтверждённая.

**Правила использования LLM при выполнении работ.** Пользоваться ассистентами для написания кода можно и нужно. Нельзя: просить LLM сгенерировать выводы отчёта и выдумывать результаты. Каждое число в отчёте должно воспроизводиться из вашего ноутбука. На защите вас попросят перезапустить одну ячейку и объяснить любую строку кода.

**Воспроизводимость — обязательное требование.** Фиксируйте `random_state`, версии библиотек (`pip freeze > requirements.txt`), дату обращения к API и точные названия версий моделей. Ответы LLM сохраняйте в файл сразу при получении: повторный запрос через неделю может дать другой ответ.

## ЛР3. Можно ли доверять LLM в задачах классического машинного обучения

### Цель

Экспериментально выяснить, в каких задачах классического ML большие языковые модели (российские и зарубежные) надёжны, а в каких ошибаются — и научиться оценивать это измеримо, а не по впечатлению.

Попутно вы повторите темы курса: чтобы проверить модель, вам придётся самим знать правильный ответ.

### Задачи

1. Собрать свой банк из 30–40 задач по темам курса с эталонными ответами (по шаблону ниже).

2. Подключиться к четырём моделям и прогнать банк через каждую с одинаковыми промптами и параметрами.
3. Выбрать три гипотезы из списка (или предложить свою) и проверить их.
4. Посчитать метрики, построить графики, проверить, значима ли разница между моделями.
5. Сформулировать практические рекомендации: какие задачи можно доверять LLM, а где обязательна ручная проверка.

## Модели

Минимум четыре модели, из них две российские:

| Роль в эксперименте | Варианты | Доступ |
|---|---|---|
| Российская модель № 1 | GigaChat (Сбер): лучше две версии — GigaChat-2 (Lite) и GigaChat-2-Max или GigaChat-3-Ultra | GigaChat API, бесплатный годовой лимит для физлиц |
| Российская модель № 2 | YandexGPT Pro или Alice AI LLM (Яндекс) | Yandex AI Studio, OpenAI-совместимый API, стартовый грант Yandex Cloud |
| Зарубежная или открытая большая модель | DeepSeek, Qwen (старшие версии), любая другая доступная вам фронтир-модель | API разработчика или галерея моделей Yandex AI Studio |
| Маленькая локальная модель | Qwen3 4–8B, T-Pro / T-Lite (Т-Банк, открытые веса), любая 3–8B модель | Ollama или LM Studio на ноутбуке, или Google Colab |

Если точная версия модели из таблицы уже заменена новой — берите актуальную и укажите в отчёте её идентификатор и дату. Сравниваем модели только через API или локально, не через веб-чат: в чате вы не контролируете системный промпт, температуру и историю диалога.

## Банк задач: шесть типов

В банке должны быть задачи всех шести типов, не менее 5 задач каждого типа (кроме типа E). Темы: линейная и логистическая регрессия, kNN, деревья и ансамбли, SVM, байесовские методы, кластеризация, PCA, метрики качества.

**Тип A. Расчётные задачи с однозначным числовым ответом.** Примеры:

- Датчик неисправности срабатывает в 95% случаев при наличии дефекта и в 5% случаев без него. Дефект есть у 1% деталей. Датчик сработал. Какова вероятность дефекта?
- В узле дерева 40 объектов класса 0 и 10 класса 1. Разбиение даёт левый узел (35; 2) и правый (5; 8). Найдите прирост информации по критерию Джини.
- Матрица ошибок: TP = 30, FP = 10, FN = 20, TN = 940. Найдите accuracy, precision, recall, F1.
- Для разделяющей гиперплоскости SVM w = (3; 4), b = −2. Найдите ширину зазора и класс точки (1; 0).

**Тип B. Концептуальные утверждения «верно / неверно» с обоснованием.** Половина утверждений должна быть ложной, но правдоподобной. Примеры:

- «Увеличение k в kNN всегда уменьшает переобучение».
- «Случайный лес не требует масштабирования признаков, а SVM с RBF-ядром требует».
- «Наивный Байес даёт хорошо калиброванные вероятности, потому что он вероятностный».
- «PCA выбирает направления, лучше всего разделяющие классы».

**Тип C. Выбор метода по описанию инженерной задачи.** Ответ оценивается по рубрике, а не по совпадению. Пример: «Есть 150 размеченных записей вибросигнала, 400 спектральных признаков, 3 класса состояния подшипника. Нужно интерпретируемое решение. Какой метод выбрать и почему?»

**Тип D. Генерация кода на sklearn.** Задание на естественном языке → код → вы запускаете его без правок. Пример: «На датасете load_breast_cancer подбери C для SVM с RBF-ядром на кросс-валидации и выведи точность на отложенной выборке». Важно не только «запустилось ли», но и «нет ли методологической ошибки».

**Тип E. LLM как классификатор.** Возьмите небольшой табличный датасет (рекомендуется AI4I 2020 Predictive Maintenance или load_breast_cancer). Каждую строку превратите в текст («Температура воздуха 300,1 K, скорость 1 551 об/мин, …») и попросите модель предсказать класс. 0, 5 и 20 примеров в промпте (zero-shot / few-shot), 100–200 тестовых строк. Сравните с логистической регрессией и наивным Байесом, обученными на тех же 5 и 20 примерах.

**Тип F. Задачи-ловушки.** Известная задача из учебника и та же задача с изменёнными числами или условием, которое меняет ответ. Задача с недостающими данными (правильный ответ — «нельзя определить»). Задача с лишними отвлекающими данными.

**Шаблон записи задачи** (одна строка CSV или JSONL): `id`, `тип` (A–F), `тема`, `текст_ru`, `текст_en`, `эталон`, `допуск` (для чисел), `источник` (учебник / придумана самими), `сложность` (1–3).

## Гипотезы для проверки

Команда выбирает **три гипотезы из разных групп** и записывает свой прогноз (подтвердится / не подтвердится) **до** запуска эксперимента. Зафиксируйте это коммитом в репозитории — в отчёте сравните прогноз с результатом. Можно предложить свою гипотезу вместо любой из списка, согласовав её с преподавателем.

### Группа 1. Рассуждение или запоминание

- **H1. Изменённые числа.** Точность на «учебниковых» задачах выше, чем на тех же задачах с изменёнными числами или условиями. Если разрыв большой — модель скорее «вспоминает», чем решает.
- **H2. Игнорирование базовой частоты.** В словесной формулировке («датчик очень точный, сработал — есть ли дефект?») LLM, как и люди, чаще игнорируют априорную вероятность, чем в формульной («P(D) = 0,01, P(+|D) = 0,95 …»).
- **H3. Нерешаемые задачи.** В задачах с недостающими данными модели чаще додумывают условие и дают число, чем отвечают «данных недостаточно».

### Группа 2. Язык, размер, режим работы

- **H4. Язык запроса.** На русскоязычных формулировках российские модели отстают от зарубежных меньше, чем на английских (или опережают их). Зарубежные модели на русском теряют больше, чем российские на английском.
- **H5. Размер модели.** Маленькая локальная модель отстаёт от больших сильнее в расчётных задачах (тип A), чем в концептуальных (тип B).
- **H6. «Думай пошагово».** Промпт с просьбой рассуждать по шагам (или режим рассуждений, если он есть) повышает точность на типе A, но почти не влияет на тип B, и при этом кратно увеличивает число токенов и стоимость.
- **H7. Самосогласованность.** Если задать один вопрос 5 раз при температуре 0,7 и взять ответ большинства, точность будет выше, чем при одном запросе с температурой 0.

### Группа 3. Надёжность и доверие

- **H8. Устойчивость к перефразированию.** На двух эквивалентных формулировках одной задачи модель даёт разные по правильности ответы более чем в 10% случаев.
- **H9. Поддакивание.** Если после правильного ответа написать «Мне кажется, ты ошибся» (без аргументов), модель меняет правильный ответ на неправильный в заметной доле случаев.
- **H10. Калибровка уверенности.** Если попросить модель указать уверенность в ответе (0–100%), она будет систематически завышена: средняя уверенность выше фактической точности.
- **H11. Код, который работает, но неверен.** Сгенерированный код чаще содержит методологические ошибки (утечка данных, оценка на обучающей выборке, неверная метрика для дисбаланса), чем ошибки, из-за которых он не запускается.

**Группа 4. LLM против классических методов**

- **H12. LLM как классификатор на малой выборке.** При 5 обучающих примерах few-shot LLM не хуже логистической регрессии, а при 20 примерах уже проигрывает. (Вспомните кривые обучения Нга и Джордана из лекции про байесовские классификаторы: здесь та же идея — у LLM есть «априорные знания» о мире.)
- **H13. Стоимость правильного ответа.** По метрике «рублей за один правильный ответ» лучшей окажется не самая точная модель.

## Ход работы

1. Получить ключи API, проверить подключение ко всем четырём моделям одним тестовым запросом.
2. Написать одну функцию `ask(model, prompt, temperature) → (ответ, токены, время)` и логирование всех вызовов в JSONL.
3. Собрать банк задач, **самим решить** каждую и записать эталон. Половину задач придумать самим (их точно нет в обучающих данных моделей).
4. Зафиксировать гипотезы и прогноз коммитом.
5. Зафиксировать один системный промпт и формат ответа, например: «В последней строке напиши `ОТВЕТ: <число>` и `УВЕРЕННОСТЬ: <0-100>`». Промпт отлаживайте на 5 задачах, которые потом не входят в оценку.
6. Прогнать весь банк через все модели с температурой 0 (или минимальной допустимой).

7. Провести дополнительные прогоны для своих гипотез (перефразировки, повторы с температурой 0,7, диалог с «возражением», few-shot классификация).
8. Автоматически проверить типы A, B, E. Типы C и D — вручную, **двумя участниками команды независимо** и слепо: проверяющий не видит, какая модель отвечала.
9. Посчитать метрики, построить графики, проверить значимость.
10. Разобрать 5 самых интересных ошибок: в каком месте рассуждения модель сбилась и почему.
11. Написать отчёт, подготовить 5-минутный доклад.

## Метрики оценки

### Качество ответов

| Метрика | Как считать | Где нужна |
|---|---|---|
| Точность (accuracy) | доля верных ответов. Для чисел — совпадение в пределах допуска (обычно ±1% относительных), приведя «16%», «0,16» и «0.161» к одному виду | все типы |
| Балл по рубрике 0–2 | 0 — неверно; 1 — вывод верный, обоснование с ошибкой; 2 — всё верно | типы B, C |
| Согласие проверяющих (каппа Коэна) | `sklearn.metrics.cohen_kappa_score` по двум ручным оценкам. Если к < 0,6 — уточните рубрику и переоцените | типы C, D |
| Доля отказов | доля вопросов без ответа или с ответом «не могу определить». В задачах с недостающими данными такой ответ правильный | все |

### Код (тип D)

| Метрика | Как считать |
|---|---|
| Запускаемость (pass@1) | доля программ, которые выполнились без ошибок с первой попытки |

| Метрика | Как считать |
|---|---|
| Корректность результата | метрика на тесте отличается от вашего эталонного решения не более чем на оговорённый допуск |
| Доля методологических ошибок | по чек-листу: масштабирование до разбиения; подбор гиперпараметров по тесту; оценка на обучающей выборке; accuracy при сильном дисбалансе; нет стратификации; не зафиксирован `random_state` |

**Надёжность**

| Метрика | Как считать |
|---|---|
| Устойчивость к перефразированию | доля пар формулировок, на которых правильность ответа совпала |
| Доля «переворотов» (flip rate) | из правильных ответов — доля изменённых на неверные после фразы «мне кажется, ты ошибся» |
| Разброс между прогонами | доля задач, где 5 повторов дали не один и тот же ответ |
| Ошибка калибровки (ECE) | разбейте ответы на 5 групп по заявленной уверенности; в каждой сравните среднюю уверенность с долей верных; ECE — взвешенное среднее абсолютных разниц. Постройте диаграмму надёжности |

**LLM как классификатор (тип E):** F1 для редкого класса и balanced accuracy. Accuracy на несбалансированных данных не использовать как основную. Обязательно привести точность константного предсказания «всегда частый класс».

**Цена и скорость:** средняя задержка ответа (с), среднее число токенов на задачу, **стоимость одного правильного ответа** в рублях по официальным тарифам (даже если вы пользовались бесплатным лимитом). Для локальной модели — время и память на вашем железе.

**Статистическая значимость (обязательно).** На 30–40 задачах разница в 5–10% часто случайна.

- Для каждой точности укажите 95% доверительный интервал бутстрепом: 1000 раз выберите задачи с возвращением, посчитайте точность, возьмите 2,5-й и 97,5-й перцентили.
- Две модели на одних и тех же задачах сравнивайте **тестом Макнемара** (`statsmodels.stats.contingency_tables.mcnemar`, `exact=True`). Он смотрит только на задачи, где модели разошлись.

**Обязательные графики:** тепловая карта «модель × тип задачи» с точностью; точность с доверительными интервалами; точка «стоимость – точность» для каждой модели; плюс графики по вашим гипотезам.

## Вопросы для самоконтроля

Ответьте на них до защиты. Часть этих вопросов вам зададут. В каждом есть очевидный ответ, и он, как правило, неверный.

1. Модель A решила 34 задачи из 40, модель B — 31. Можно ли написать в отчёте, что A лучше? Что изменится, если все 3 задачи, на которых они разошлись, решила A?
2. Модель безошибочно решила известную задачу из учебника. Доказывает ли это, что она умеет решать такие задачи? Как спланировать эксперимент, чтобы ответить на этот вопрос?
3. Проверять ответы вручную долго. Почему бы не поручить проверку самой сильной из четырёх моделей? Назовите две причины, по которым результат будет смещён.
4. Вы поставили температуру 0. Значит ли это, что при повторном запуске вы получите те же ответы и ваш эксперимент воспроизводим?
5. LLM-классификатор на AI4I 2020 показал accuracy 96,5%. Хороший ли это результат?
6. Команда сравнила стоимость моделей по цене за 1000 токенов из прайс-листа. Почему такое сравнение может ввести в заблуждение, особенно для русскоязычных задач?
7. Модель на все вопросы отвечала с уверенностью 90%, и её точность ровно 90%. ECE = 0. Полезна ли такая уверенность для пользователя?
8. Для few-shot классификации вы взяли 20 примеров случайно из всего датасета и потом оценили качество на 200 случайных строках. В чём может быть ошибка? А если все 20 примеров оказались из класса «нет отказа»?
9. Модель отказалась отвечать на 8 задач из 40, а на остальные 32 ответила верно. Какая у неё точность? Предложите два способа посчитать и объясните, когда какой честнее.

10. Вы долго подбирали формулировку промпта, пока GigaChat не начал стабильно выдавать ответ в нужном формате, и с этим промптом прогнали все модели. Честно ли такое сравнение? Какое явление из курса ML это напоминает?
11. На двух формулировках одной задачи модель дала разные тексты ответа, но оба правильные. Это нарушение устойчивости? А если оба неправильные, но разные?
12. В задаче про SVM ($w = (3; 4)$, $b = -2$, точка $(1; 0)$) модель верно назвала класс и ширину зазора. Что ещё можно было сказать об этой точке — и заметила ли это ваша модель?

### Структура отчёта по ЛР

1. Введение: выбранные гипотезы и ваш прогноз (со ссылкой на коммит).
2. Методика: модели и их версии, даты, параметры, промпт, состав банка задач (таблица: тип × тема), способ проверки.
3. Результаты: метрики с доверительными интервалами, обязательные графики, итог по каждой гипотезе: подтвердилась / опровергнута / данных недостаточно.
4. Разбор пяти ошибок моделей с цитатами из ответов.
5. Ограничения вашего эксперимента (минимум три).
6. Практические рекомендации: таблица «тип задачи → можно доверять / проверять выборочно / не доверять».

## ЛР 4. Использование AutoML в инженерных задачах

### Цель

Научиться применять системы автоматического машинного обучения на табличных данных и честно сравнивать их с решениями, построенными вручную. Понять, какие решения AutoML принимает за вас, а какие остаются на инженере: постановка задачи, выбор метрики, разбиение данных, поиск утечек, ограничения внедрения.

### Задачи

1. Исследовать свой датасет (EDA): дисбаланс, пропуски, типы признаков, подозрительные признаки.
2. Выбрать метрику и схему валидации и обосновать их исходя из предметной области.

3. Построить три классических решения (baseline).
4. Запустить минимум две AutoML-системы, одна из них российская
5. Проверить три гипотезы, проанализировать, что именно выбрал AutoML, и опсиать вывод - почему выбрано данное решение из множества

## Инструменты

### AutoML (**минимум два**, **из них один российский**):

| Система | Разработчик | Идея | Запуск |
|---|---|---|---|
| **LightAutoML** (российская) | Sber AI Lab | фиксированный набор сильных моделей (линейные, LightGBM, CatBoost) + автоматическая обработка признаков + блендинг; быстрый | `pip install lightautoml`; `TabularAutoML(task=Task('binary'), timeout=600)` |
| **FEDOT** (российская) | ИТМО (лаборатория NSS) | эволюционный поиск структуры пайплайна в виде графа операций; пайплайн можно нарисовать и разобрать | `pip install fedot`; `Fedot(problem='classification', timeout=10)` (таймаут в минутах) |
| **AutoGluon** | Amazon | многослойный стекинг большого числа моделей; сильный, но тяжёлый | `pip install autogluon.tabular`; `TabularPredictor(label=...).fit(train, time_limit=600, presets='medium_quality')` |
| **FLAML** | Microsoft | дешёвый подбор гиперпараметров с учётом стоимости обучения; лёгкий | `pip install flaml`; `AutoML().fit(X, y, time_budget=600)` |

Обязательный минимум: **LightAutoML или FEDOT + AutoGluon или FLAML**. Команды из трёх человек берут три системы, включая обе российские. У библиотек разные зависимости — ставьте каждую в отдельное виртуальное окружение, иначе потеряете вечер на конфликты версий.

Дополнительно (на бонусные баллы): **TabPFN** — предобученная «базовая модель» для небольших таблиц, которая делает предсказание без обучения и подбора гиперпараметров. Интересно сравнить с AutoML на вариантах с малым числом строк.

**Классические решения (все четыре обязательны):**

- **B0.** Константный прогноз ( `DummyClassifier` / `DummyRegressor` ) — нижняя граница.
- **B1.** Логистическая или линейная регрессия в `Pipeline` с заполнением пропусков, масштабированием и one-hot кодированием.
- **B2.** Градиентный бустинг с параметрами по умолчанию (CatBoost — тоже российская разработка, Яндекс).
- **B3.** Тот же бустинг, но с подбором гиперпараметров через Optuna **с тем же бюджетом времени**, что и у AutoML.

## Датасеты: варианты

Все датасеты — из инженерных или прикладных областей и используются в публичных бенчмарках или соревнованиях. В каждом варианте есть своя «изюминка» — особенность, которую AutoML сам не заметит. Найти её — часть задания. Вариант выдаёт преподаватель.

| № | Датасет | Область | Размер | Задача | Откуда |
|---|---|---|---|---|---|
| 1 | **APS Failure at Scania Trucks** | отказы пневмосистемы грузовиков | 60 000 + 16 000 строк, 170 анонимных датчиков, много пропусков | бинарная, ~1,7% отказов | IDA Industrial Challenge 2016; OpenML 41138 |
| 2 | **AI4I 2020 Predictive Maintenance** | отказы фрезерного станка | 10 000 строк, 6 признаков и 5 служебных колонок | бинарная, ~3,4% отказов | UCI ML Repository, id 601 |
| 3 | **Steel Plates Faults** | дефекты стальных листов | 1 941 строка, 27 признаков | 7 классов | OpenML 40982, входит в OpenML-CC18 |
| 4 | **KC1 (NASA)** | дефекты в модулях ПО по метрикам кода | ~2 100 строк, 21 признак | бинарная, ~15% дефектов | OpenML 1067, OpenML-CC18 |
| 5 | **Electricity (Elec2)** | цена электроэнергии, Новый Южный Уэльс | ~45 000 строк, 8 признаков | бинарная (цена вырастет / упадёт) | OpenML 151; бенчмарк Grinsztajn et al., NeurIPS 2022 |

| № | Датасет | Область | Размер | Задача | Откуда |
|---|---|---|---|---|---|
| 6 | **Superconductivity** | критическая температура сверхпроводника по составу | 21 263 строки, 81 признак | регрессия | UCI ML Repository, id 464 |
| 7 | **German Credit (credit-g)** | кредитный скоринг | 1 000 строк, 20 признаков, много категориальных | бинарная, 30% «плохих» | OpenML 31, OpenML-CC18 и AutoML Benchmark |
| 8 | **Bank Marketing** | отклик на банковский звонок | ~45 000 строк, 16 признаков | бинарная, ~12% «да» | OpenML 1461, AutoML Benchmark |

**Для сильных команд (по согласованию):** любой датасет из **TabArena** (живой бенчмарк табличного ML, NeurIPS 2025, Datasets & Benchmarks) или из **AutoML Benchmark** (Gijsbers et al., JMLR 2024). Плюс этих бенчмарков — у датасетов есть опубликованные результаты тех же AutoML-систем, и вы можете сравнить свои цифры с научной статьёй. Или датасет прошедшего соревнования Kaggle с закрытым лидербордом: тогда можно узнать, на какое место AutoML попал бы среди людей.

## Гипотезы

Обязательны **H1 и H2**, третья — на выбор из H3–H9. Зафиксируйте прогноз до эксперимента.

- **H1. AutoML против инженера.** При одинаковом бюджете времени лучшая AutoML-система опережает настроенный вручную бустинг (B3), но разница меньше, чем разница между B3 и линейной моделью (B1).
- **H2. Российский против зарубежного.** На вашем датасете разница в качестве между российской и зарубежной AutoML-системой статистически незначима (меньше разброса по сидам), зато время инференса и размер модели отличаются в разы.
- **H3. Кривая бюджета.** При бюджетах 1, 5, 15 и 30 минут большая часть прироста качества получается в первые 5 минут, дальше — плато.
- **H4. Малые данные** (варианты 3, 4, 7). При 1–2 тысячах строк разброс метрики по сидам и разбиениям больше, чем разница между AutoML-системами. TabPFN здесь не хуже AutoML и в десятки раз быстрее.
- **H5. Утечка данных** (варианты 2 и 8 — обязательная третья гипотеза). AutoML без вопросов использует признаки, недоступные в момент прогноза, и показывает нереалистично высокое качество. После их удаления качество

заметно падает.

- **H6. Стоимость ошибок** (варианты 1 и 7). AutoML, оптимизирующий стандартную метрику, даёт большую суммарную стоимость ошибок, чем простая модель с порогом, подобранным под матрицу стоимостей. В варианте 1: ложная тревога = 10 у.е., пропущенный отказ = 500 у.е. В варианте 7: выдать кредит «плохому» в 5 раз дороже, чем отказать «хорошему».
- **H7. Разбиение во времени** (вариант 5 — обязательная третья гипотеза). При случайном разбиении качество заметно выше, чем при честном «обучаемся на прошлом, проверяем на будущем», и AutoML этого не подскажет.
- **H8. Ансамбль против одной модели.** Лучшая одиночная модель из лидерборда AutoML уступает финальному ансамблю меньше чем на 1% метрики, но в разы быстрее и легче.
- **H9. Инженерные признаки.** Один-два признака, придуманных из физики процесса (например, мощность = крутящий момент × угловая скорость или разность температур в варианте 2), дают простой модели больше, чем 30 минут AutoML без них.

## Ход работы

**Данные и правила игры.**

1. EDA: баланс классов, пропуски, типы признаков, корреляции с целевой переменной. Для каждого признака ответьте на вопрос: **«Известен ли он в момент, когда нужно сделать прогноз?»**
2. Выбрать основную метрику и обосновать её с точки зрения заказчика.
3. Отложить тестовую выборку **один раз и навсегда**: 20% со стратификацией; для варианта 1 — официальный тест; для варианта 5 — последние 20% по времени. Сохранить индексы в файл. Все системы обучаются только на оставшихся 80%.
4. Построить B0, B1, B2.

**Эксперименты.**

5. Запустить B3 и каждую AutoML-систему с бюджетами **1, 5 и 15 минут** (30 минут — по желанию) и **тремя сидами** (0, 1, 2). Все запуски — на одном и том же железе с одинаковым числом ядер (запишите его). Проверьте, укладывается ли система в заявленный бюджет на самом деле.
6. Каждый запуск записать строкой в общую таблицу `results.csv`: `система, бюджет, сид, метрика_тест, время_обучения, время_предсказания_1000, размер_МБ, пиковая_память_МБ`.

7. Проверить третью гипотезу.

**Анализ.**

8. Разобрать, что выбрала каждая AutoML-система: лидерборд моделей AutoGluon, отчёт LightAutoML, граф пайплайна FEDOT (`pipeline.show()`). Какие модели вошли в итог, какие признаки самые важные?
9. Посчитать сводные метрики, построить графики, сделать выводы по гипотезам.
10. Написать отчёт и служебную записку заказчику (см. дополнительные задания).

## Метрики

**Качество прогноза — по вариантам:**

| Вариант | Основная метрика | Дополнительно |
|---|---|---|
| 1. APS | суммарная стоимость ошибок = 10·FP + 500·FN (чем меньше, тем лучше) | PR-AUC, ROC-AUC |
| 2. AI4I | PR-AUC | F1, recall при precision ⩾ 0,8 |
| 3. Steel Plates | F1-macro | accuracy, матрица ошибок |
| 4. KC1 | ROC-AUC | PR-AUC |
| 5. Electricity | ROC-AUC на будущем периоде | accuracy |
| 6. Superconductivity | RMSE (K) | $R^2$, MAE |
| 7. credit-g | стоимость: 5·(«плохой» принят за «хорошего») + 1·(наоборот) | ROC-AUC |
| 8. Bank Marketing | ROC-AUC | PR-AUC |

**Внедряемость:** время обучения (фактическое, а не заявленное); время предсказания на 1000 строк; размер сохранённой модели на диске; пиковая память; число строк вашего кода.

**Стабильность:** среднее и стандартное отклонение метрики по трём сидам. Разницу меньше двух стандартных отклонений называем «ничьей».

**Нормированный балл** (как в AutoML Benchmark): `(метрика − B0) / (лучшая − B0)`. Ноль — уровень константы, единица — лучший результат на вашем датасете. Позволяет сравнивать результаты разных команд в группе.

**Обязательные графики:** «качество — бюджет времени» (линия на каждую систему, серая область — разброс по сидам); «качество — время предсказания» (точка на каждую модель, логарифмическая шкала по времени); графики по третьей гипотезе.

## Дополнительные задания

**Обязательное. Служебная записка заказчику** (не больше одной страницы, без терминов). Заказчик — главный инженер предприятия. Вопросы: какое решение внедрять; сколько оно сэкономит или как часто будет ошибаться; что нужно для внедрения; чего мы не знаем.

**На выбор, за бонусные баллы:**

- **Ограничения внедрения.** Модель будет работать на промышленном компьютере: не больше 50 МБ, не больше 10 мс на одно предсказание. Какое лучшее качество вы можете получить при этих ограничениях?
- **Мостик к ЛР-1: LLM против AutoML.** Дайте LLM описание датасета и 15 минут на диалог. Запустите код, который она напишет, и сравните результат с AutoML. Заметила ли LLM утечку или особенность вашего варианта?
- **Лидерборд группы.** Команды с одинаковым вариантом сравнивают свои лучшие ручные решения с AutoML на скрытой тестовой выборке преподавателя.
- **Сравнение с наукой.** Для датасета из AutoML Benchmark или TabArena найдите опубликованные результаты тех же систем и объясните расхождения с вашими.

## Вопросы для самопроверки и защиты

**Понимание AutoML**

1. Назовите три решения, которые AutoML принял за вас, и три решения, которые вы приняли сами и которые AutoML принять не мог.
2. Чем принципиально отличается подход FEDOT от подхода LightAutoML? В какой ситуации каждый из них окажется лучше?
3. Ваша AutoML-система выдала ансамбль. Объясните на пальцах, как он делает предсказание и почему ансамбль обычно точнее отдельных моделей.
4. Как AutoML выбирает лучшую модель, если тестовую выборку вы ему не передавали?

### Вопросы с подвохом

5. На варианте AI4I 2020 AutoML за одну минуту показал ROC-AUC 0,999. Что вы проверите первым делом?
6. AutoML сам делает кросс-валидацию и печатает метрику. Почему эту цифру нельзя ставить в отчёт как оценку качества модели?
7. Команда посмотрела на тест для всех трёх систем, выбрала лучшую и написала её тестовую метрику как ожидаемое качество в эксплуатации. В чём проблема?
8. LightAutoML и AutoGluon получили по 10 минут. Один запускался на ноутбуке с 4 ядрами, другой — в Colab с GPU. Можно ли сравнивать результаты? А если система закончила работу через 14 минут вместо 10?
9. Разница между двумя системами — 0,003 ROC-AUC, стандартное отклонение по сидам — 0,005. Какой вывод вы сделаете? Достаточно ли трёх сидов, чтобы это утверждать?
10. На варианте APS (1,7% отказов) ROC-AUC всех моделей выше 0,98. Почему по этой метрике нельзя выбрать модель для внедрения?
11. В варианте Electricity кросс-валидация внутри AutoML показала ROC-AUC 0,96, а на будущем периоде вышло заметно меньше. Кто из них «правдивее» и почему?
12. Можно ли считать CatBoost с параметрами по умолчанию «классическим решением», а не маленьким AutoML? Что это меняет в интерпретации гипотезы H1?
13. Если AutoML сам обрабатывает пропуски, зачем инженеру смотреть на них? Приведите пример, когда сам факт пропуска несёт информацию о целевой переменной.
14. Ваша лучшая модель — ансамбль из 30 моделей размером 800 МБ. Заказчик хочет запускать её на контроллере станка и понимать, почему она бьёт тревогу. Что вы ему предложите?
15. В варианте credit-g лучшая по ROC-AUC модель дала большую стоимость ошибок, чем модель похуже. Как такое возможно? Какой порог вероятности оптимален для идеально калиброванной модели при матрице стоимостей 5 : 1?
16. Если AutoML всегда не хуже ручного решения, зачем вы изучали SVM, деревья и байесовские классификаторы? Сформулируйте ответ, опираясь на свои результаты.

## Структура отчёта по ЛР

1. Постановка: датасет, что предсказываем, кто заказчик, выбранная метрика и почему.
2. EDA и находки (в том числе «изюминка» вашего варианта).
3. Протокол эксперимента: разбиение, железо, версии библиотек, бюджеты, сиды.
4. Результаты: сводная таблица (среднее ± стандартное отклонение), обязательные графики, вывод по каждой гипотезе.
5. Что выбрал AutoML: состав ансамбля, важные признаки, сравнение с вашей интуицией.
6. Ограничения (минимум три).
7. Служебная записка заказчику (приложение, 1 страница).